

Estimation and Hypothesis Testing 2 | *Les estimateurs et les tests d'hypothèses 2*

Adikath + Macartan; Vin + Yannick

2026-06-09

A Quick Reminder

Un petit rappel

- Remember: Analyze as you randomize
 - We prefer estimators that are unbiased and have greater precision
 - Hypothesis testing can be simple with linear regression
- N'oubliez pas : analysez comme vous randomisez
 - Nous préférons les estimateurs non biaisés et plus précis
 - Les tests d'hypothèse peuvent être simples avec la régression linéaire

Section 1

Multiple Arm Experiments

Estimator 1: Difference-in-Means

Estimateur 1 : La différence en moyennes

Z_A only	Z_B only	Neither (control)
------------	------------	-------------------

- We can always take the difference-in-means between any two groups.
- Nous pouvons toujours tenir compte de la différence de moyennes entre deux groupes.

Estimator 2: Linear regression

Estimateur 2 : La régression linéaire

$$Y_i = \alpha + \beta_A Z_{Ai} + \beta_B Z_{Bi} + e_i$$

$$Y_i = \alpha + \beta_A Z_{Ai} + \beta_B Z_{Bi} + \gamma X_i + e_i$$

- Regression with an indicator variable for each of the two treatment arms.
 - $Z_{Ai} = 1$ if unit i has treatment Z_A , 0 otherwise
 - $Z_{Bi} = 1$ if unit i has treatment Z_B , 0 otherwise
 - We can also do covariate adjustment at the same time.
- Régression avec une variable indicatrice pour chacun des deux bras de traitement.
 - $Z_{Ai} = 1$ si l'unité i a le traitement Z_A , sinon 0
 - $Z_{Bi} = 1$ si l'unité i a le traitement Z_B , sinon 0
 - Nous pouvons également effectuer un ajustement covariable en même temps.

Estimator 2: Linear regression


Estimateur 2 : La régression linéaire

$$Y_i = \alpha + \beta_A Z_{Ai} + \beta_B Z_{Bi} + e_i$$

- $\hat{\beta}_A$ is the $\widehat{ATE}$ of Z_A (compared with control).
 - $\hat{\beta}_B$ is the $\widehat{ATE}$ of Z_B (compared with control).
 - How do we estimate the effect of Z_B compared to Z_A ?
- $\hat{\beta}_A$ est $\widehat{ATE}$ de Z_A (par rapport au contrôle).
 - $\hat{\beta}_B$ est $\widehat{ATE}$ de Z_B (par rapport au contrôle).
 - Comment estimer l'effet de Z_B par rapport à Z_A ?

Estimator 2: Linear regression

Estimateur 2 : La régression linéaire



Z_A only

Z_B only

Neither (control)

$$Y_i = \alpha + \beta_A Z_{Ai} + \beta_B Z_{Bi} + e_i$$

Estimators for Multi-arm Designs

Les estimateurs pour les expériences avec plusieurs bras

Section 2

Block Randomization

Block Randomization

Randomisation par bloc

- Block randomization is like doing a separate experiment in each block.
- We present 2 estimators for block randomization. Others are also available.
- La randomisation par bloc est comme faire une expérience distincte dans chaque bloc.
- Nous présentons 2 estimateurs pour la randomisation par bloc. D'autres sont également disponibles.

Estimator 1: Blocked Difference-in-Means

Estimateur 1 : La différence des moyennes par bloc

- Calculate the $\widehat{ATE}_j$ for each block using difference in means. j indicates which block.
 - The $\widehat{ATE}$ is the average of the block-level $\widehat{ATE}_j$ weighted by block size N_j/N .
 - You can use this estimator even when the probability of treatment assignment is different by blocks.
- Calculez $\widehat{ATE}_j$ pour chaque bloc en utilisant la différence des moyennes.
 - $\widehat{ATE}$ est la moyenne pondérée de $\widehat{ATE}_j$ pondérée par la taille du bloc N_j/N .
 - Nous pouvons utiliser cet estimateur même si la probabilité d'assignation du traitement diffère selon les blocs.

Estimator 1: Blocked Difference-in-Means

Estimateur 1 : La différence des moyennes par bloc

Unit	Block	Z_i	Y_i
a	Q	0	4
b	Q	1	3
c	Q	0	2
d	R	1	3
e	R	0	0
f	R	0	2
g	S	1	4
h	S	0	0
i	S	0	2
j	S	1	4

$$\widehat{ATE}_Q = \frac{3}{1} - \frac{4+2}{2} = 0$$

$$\widehat{ATE}_R = \frac{3}{1} - \frac{0+2}{2} = 2$$

$$\widehat{ATE}_S = \frac{4+4}{2} - \frac{0+2}{2} = 3$$

$$\begin{aligned}\widehat{ATE} &= \frac{N_Q}{N} \widehat{ATE}_Q + \frac{N_R}{N} \widehat{ATE}_R + \frac{N_S}{N} \widehat{ATE}_S \\ &= \frac{3}{10} * 0 + \frac{3}{10} * 2 + \frac{4}{10} * 3 = \frac{9}{5}\end{aligned}$$

Estimator 2: Linear Regression with Block Fixed Effects

Estimateur 2 : La régression linéaire avec effets fixes par bloc

$$Y_{ij} = \alpha_0 + \beta_1 Z_{ij} + \gamma_A \text{Block} A_{ij} + \gamma_B \text{Block} B_{ij} + \dots + \epsilon_{ij}$$

- You can use linear regression with block fixed effects, applying weights to each observation.
- The weight is the inverse of the proportion of subjects in the same block who were assigned to the same condition.
- Nous pouvons utiliser la régression linéaire avec des effets fixes par bloc, en appliquant des pondérations à chaque observation.
- Le poids est l'inverse de la proportion de sujets d'un même bloc assignés à la même condition.

$$w_{ij} = \frac{z_i}{p_{ij}} + \frac{1 - z_i}{1 - p_{ij}}, \text{ where } p_{ij} \equiv \frac{m_j}{N_j}$$

Block randomization in R

Randomisation par bloc en R

```
library(estimatr)
difference_in_means(Y ~ t, blocks = block_1)

lm_robust(Y ~ treatment + as.factor(block_1),
           weights = weight_variable)
```

```
library(estimatr)
difference_in_means(Y ~ t, blocks = block_1)

lm_robust(Y ~ treatment + as.factor(block_1),
           weights = weight_variable)
```

Section 3

Cluster Randomization

Estimator: Regression with cluster-robust standard errors

Estimateur : La régression avec des erreurs types robustes au niveau du cluster

$$Y_{ic} = \alpha_0 + \beta_1 Z_c + e_{ic}$$

$$Y_{ic} = \alpha_0 + \beta_1 Z_c + \gamma X_{ic} + e_{ic}$$

- Our analysis has to take into account the fact that treatment is assigned at the cluster level with *cluster-robust standard errors*.
- $\hat{\beta}_1$ is the $\widehat{ATE}$ of the treatment on individual units.
- We can also do covariate adjustment at the same time.
- Notre analyse doit prendre en compte le fait que le traitement est attribué au niveau du cluster avec des *erreurs types robustes au niveau du cluster*.
- $\hat{\beta}_1$ est $\widehat{ATE}$ du traitement sur les unités individuelles.
- Nous pouvons également effectuer un ajustement covariable en même temps.

Cluster randomization

Randomisation par grappe

Table 2 | Effect of treatment on movement outcomes

Campaign	Outcome	Period	Mean (95% CI)		OLS model			Number of days × counties
			High-intensity county	Low-intensity county	High-intensity county (95% CI)	P value	RI P value	
Both campaigns	Distance traveled	From day – 3 to day – 1	–4.384 (–4.973, –3.796)	–3.603 (–4.254, –2.952)	–0.993 (–1.616, –0.371)	0.002	0.002	4,059
Both campaigns	Share ever left home	Thanksgiving (26 November) or Christmas (24–25 December)	72.326 (72.012, 72.639)	72.381 (72.092, 72.670)	0.030 (–0.361, 0.420)	0.881	0.911	2,017
Thanksgiving	Distance traveled	From day – 3 to day – 1	–6.082 (–6.822, –5.341)	–5.320 (–6.113, –4.527)	–0.924 (–1.785, –0.063)	0.035	0.030	2,072
Thanksgiving	Share ever left home	Thanksgiving (26 November)	71.308 (70.885, 71.731)	71.468 (71.071, 71.866)	0.012 (–0.438, 0.461)	0.959	0.966	689
Christmas	Distance traveled	From day – 3 to day – 1	–2.603 (–3.279, –1.927)	–1.823 (–2.588, –1.057)	–1.041 (–1.847, –0.235)	0.011	0.008	1,987
Christmas	Share ever left home	Christmas (24–25 December)	72.859 (72.507, 73.210)	72.852 (72.520, 73.185)	0.095 (–0.289, 0.479)	0.629	0.580	1,328

The control and treatment means at the county level and different periods, in addition to the estimate of the treatment coefficient in Eq. (1). Standard errors are clustered at the county level. 95% CIs are reported in parentheses. P values are based on a two-sided test. RI P values are computed using randomization inference, accounting for the two-stage design.

```
library(estimatr)
```

```
lm_robust(Y ~ treatment, clusters = cluster_id)
```

```
lm_robust(Y ~ treatment + covariate, clusters = cluster_id)
```

```
library(estimatr)
```

```
lm_robust(Y ~ treatment, clusters = cluster_id)
```

```
lm_robust(Y ~ treatment + covariate, clusters = cluster_id)
```

Section 4

Factorial Design

Estimator 1: Difference-in-Means

Estimateur 1 : La différence en moyennes

	$Z_2 = 0$	$Z_2 = 1$	Effect of Z_2
$Z_1 = 0$	Neither	Z_2 only	β_2
$Z_1 = 1$	Z_1 only	Both Z_1 and Z_2	$\beta_2 + \beta_3$
Effect of Z_1	β_1	$\beta_1 + \beta_3$	β_3 (diff-in-diff)

- We use factorial design when we are interested in interaction effects.
 - If we have a 2×2 factorial design, we have four groups.
 - We can always take the difference-in-means between any two groups.
- Nous utilisons un plan factoriel quand nous nous intéressons aux effets d'interaction.
 - Si nous avons une conception factorielle 2×2 , nous avons 4 groupes.
 - Nous pouvons toujours tenir compte de la différence de moyennes entre deux groupes.

Estimator 2: Linear Regression with an Interaction Term

Estimateur 2 : La régression linéaire avec un terme d'interaction

$$Y_i = \alpha_0 + \beta_1 Z_{1i} + \beta_2 Z_{2i} + \beta_3 Z_{1i} * Z_{2i} + e_i$$

$$Y_i = \alpha_0 + \beta_1 Z_{1i} + \beta_2 Z_{2i} + \beta_3 Z_{1i} * Z_{2i} + \gamma X_i + e_i$$

- Indicator variables for Z_1 and Z_2 .
- We can also do covariate adjustment at the same time.
- Variables indicatrices pour Z_1 et Z_2 .
- Nous pouvons également effectuer un ajustement covariable en même temps.

Estimator 2: Linear Regression with an Interaction Term

Estimateur 2 : La régression linéaire avec un terme d'interaction

	$Z_2 = 1$	$Z_2 = 0$
$Z_1 = 1$	Both Z_1 and Z_2	Z_1 only
$Z_1 = 0$	Z_2 only	Neither

$$Y_i = \alpha_0 + \beta_1 Z_{1i} + \beta_2 Z_{2i} + \beta_3 Z_{1i} * Z_{2i} + e_i$$

- Estimand: $E[Y(Z_1 = 1)|Z_2 = 0] - E[Y(Z_1 = 0)|Z_2 = 0]$
- $\hat{\beta}_1$ is the $\widehat{ATE}$ of Z_1 conditional on $Z_2 = 0$.
- Paramètre : $E[Y(Z_1 = 1)|Z_2 = 0] - E[Y(Z_1 = 0)|Z_2 = 0]$
- $\widehat{ATE}$ de Z_1 conditionnel à $Z_2 = 0$.

Estimator 2: Linear Regression with an Interaction Term

Estimateur 2 : La régression linéaire avec un terme d'interaction

	$Z_2 = 1$	$Z_2 = 0$
$Z_1 = 1$	Both Z_1 and Z_2	Z_1 only
$Z_1 = 0$	Z_2 only	Neither

$$Y_i = \alpha_0 + \beta_1 Z_{1i} + \beta_2 Z_{2i} + \beta_3 Z_{1i} * Z_{2i} + e_i$$

- Estimand: $E[Y(Z_1 = 1)|Z_2 = 1] - E[Y(Z_1 = 0)|Z_2 = 1]$
- $\hat{\beta}_1 + \hat{\beta}_3 = \widehat{ATE}$ of Z_1 conditional on $Z_2 = 1$
- β_3 is called the interaction effect.
- Paramètre : $E[Y(Z_1 = 1)|Z_2 = 1] - E[Y(Z_1 = 0)|Z_2 = 1]$
- $\widehat{ATE}$ de Z_1 conditionnel à $Z_2 = 1$
- β_3 est appelé l'effet d'interaction.

Estimator 2: Linear Regression with an Interaction Term

Estimateur 2 : La régression linéaire avec un terme d'interaction

```
lm_robust(Energy ~ Coffee * Sport, data = df)
```

Statistical models

Model 1

(Intercept)

0.15

(0.14)

Coffee

0.42*

(0.19)

Estimator 2: Linear Regression with an Interaction Term

Estimateur 2 : La régression linéaire avec un terme d'interaction

$\hat{Y} \text{Coffee} = 0, \text{Sport} = 0$	$\hat{\alpha} = 0.154$
$\hat{Y} \text{Coffee} = 0, \text{Sport} = 1$	$\hat{\alpha} + \hat{\beta}_2 = 0.424$
$\hat{Y} \text{Coffee} = 1, \text{Sport} = 0$	$\hat{\alpha} + \hat{\beta}_1 = 0.576$
$\hat{Y} \text{Coffee} = 1, \text{Sport} = 1$	$\hat{\alpha} + \hat{\beta}_1 + \hat{\beta}_2 + \hat{\beta}_3 = 1.105$
$\widehat{ATE} \text{ of Coffee} \text{Sport} = 0$	$\hat{\beta}_1 = 0.422$
$\widehat{ATE} \text{ of Coffee} \text{Sport} = 1$	$\hat{\beta}_1 + \hat{\beta}_3 = 0.681$
Interaction effect	$\hat{\beta}_3 = 0.260$

$\hat{Y} \text{Coffee} = 0, \text{Sport} = 0$	$\hat{\alpha} = 0.154$
$\hat{Y} \text{Coffee} = 0, \text{Sport} = 1$	$\hat{\alpha} + \hat{\beta}_2 = 0.424$
$\hat{Y} \text{Coffee} = 1, \text{Sport} = 0$	$\hat{\alpha} + \hat{\beta}_1 = 0.576$
$\hat{Y} \text{Coffee} = 1, \text{Sport} = 1$	$\hat{\alpha} + \hat{\beta}_1 + \hat{\beta}_2 + \hat{\beta}_3 = 1.105$
$\widehat{ATE} \text{ de Coffee} \text{Sport} = 0$	$\hat{\beta}_1 = 0.422$
$\widehat{ATE} \text{ de Coffee} \text{Sport} = 1$	$\hat{\beta}_1 + \hat{\beta}_3 = 0.681$
Effet d'interaction	$\hat{\beta}_3 = 0.260$

$$\hat{Y} = 0.154 + 0.422 \times \text{Coffee} + 0.270 \times \text{Sport} + 0.260 \times \text{Coffee} \times \text{Sport}$$