

Power and more | *Puissance statistique*

Macartan, Alyssa

2026-06-09

Section 1

Outline

Overview

Vue d'ensemble

- ① Tests review
- ② p values and significance
- ③ Power
- ④ Sources of power

- ① Rappel sur les tests
- ② p -values et significativité
- ③ Puissance
- ④ Sources de puissance

Section 2

Tests

In the classical approach we ask:

How likely are we to see data like this if the hypothesis is true?

- If the answer is “not very likely”, we treat the hypothesis as suspect.
- Otherwise we **maintain** it (not quite “accept” — we may maintain incompatible hypotheses).

How unlikely is “not very likely”?

Dans l'approche classique, on se demande :

Quelle est la probabilité d'observer de telles données si l'hypothèse est vraie ?

- Si la réponse est « peu probable », l'hypothèse devient suspecte.
- Sinon, on la **maintient** (pas vraiment « accepter » — on peut maintenir des hypothèses incompatibles).

Qu'est-ce que « peu probable » ?

Weighing evidence

Peser les preuves

Before testing, decide what evidence would convince you the hypothesis is unreliable.

Othello believes Desdemona is innocent. **Iago** offers evidence:

- Would she look at Cassio like that if innocent?
- Would she defend him like that?
- Would Cassio have her handkerchief?

Othello: the chance of all this if she were innocent is surely below 5%.

Avant de tester, fixez quelles preuves vous feraient douter de l'hypothèse.

Othello croit Desdemona innocente. **Iago** avance :

- La regarderait-elle ainsi si elle était innocente ?
- Le défendrait-elle ainsi ?
- Cassio aurait-il son mouchoir ?

Othello : la probabilité de tout cela si elle était innocente est sûrement inférieure à 5 %.

Frequentist vs Bayesian

Fréquentiste vs bayésien

Othello focuses on $\Pr(\text{Data} \mid \text{Hypothesis TRUE})$ — not on $\Pr(\text{Hypothesis TRUE} \mid \text{Data})$.

He assesses how likely the data would be **if** she were faithful — not his belief in her fidelity.

Hypotheses are often **rejected**, sometimes **maintained**, rarely **accepted**.

Othello se concentre sur $\Pr(\text{Données} \mid \text{Hypothèse VRAIE})$ — pas sur $\Pr(\text{Hypothèse VRAIE} \mid \text{Données})$.

Il évalue la probabilité des données **si** elle était fidèle — pas sa croyance en sa fidélité.

Les hypothèses sont souvent **rejetées**, parfois **maintenues**, rarement **acceptées**.

p values in your head

p values in your head

You randomized treatment assignment. Your data:

Vous avez randomisé l'assignation au traitement.
Vos données :

Unit	1	2	3	4	5	6	7	8	9	10
Treatment	0	0	0	0	0	0	0	1	0	0
Health score	4	2	3	1	2	3	4	8	7	6

p value questions

Questions sur la p -value

- Does treatment improve health?
- What is the p value for the null that treatment had **no effect on anybody**?
- Le traitement améliore-t-il la santé ?
- Quelle est la p -value pour l'hypothèse nulle d'**aucun effet sur personne** ?

Section 3

Power

What is power?

Qu'est-ce que la puissance ?

Power is the probability of **rejecting** a hypothesis.

It presupposes:

- a well-defined hypothesis
- a stipulation of how the world actually works
- a procedure for producing results and deciding significance

La **puissance** est la probabilité de **rejeter** une hypothèse.

Elle présuppose :

- une hypothèse bien définie
- une description du monde tel qu'on le croit vrai
- une procédure pour produire des résultats et décider de la significativité

Dice: one roll

Dé : un lancer

Hypothesis: a six **never** comes up on this die.

Test:

- Roll **once**.
- Reject if a six appears.


What is the power of this test?

Hypothese : un six **ne sort jamais** sur ce dé.

Test :

- Lancer **une fois**.
- Rejeter si un six apparaît.

Quelle est la puissance de ce test ?




Dice: two rolls

Dé : deux lancers

Same hypothesis — but roll **twice**.
Reject if a six appears **either time**.
What is the power of **this** test?

Même hypothèse — mais lancer **deux fois**.
Rejeter si un six apparaît **l'une ou l'autre fois**.
Quelle est la puissance de **ce** test ?



Two probabilities

Deux probabilités

Power can seem harder because rejection involves a **calculated** probability — a probability of a probability.

Hypothesis: the die is **fair**.

- Roll **1000** times.
- Reject if fewer than x sixes or more than y sixes.

What should x and y be?

La puissance peut sembler plus difficile car le rejet implique une probabilité **calculée** — une probabilité de probabilité.

Hypothèse : le dé est **équitable**.

- Lancer **1000** fois.
- Rejeter si moins de x six ou plus de y six.

Que valent x et y ?

Step 1: rejection rule


Étape 1 : règle de rejet

Set a rejection rule based on events unlikely under the hypothesis.

Expected number of sixes if the die is fair:

Fixer une règle de rejet à partir d'événements improbables sous l'hypothèse.

Nombre attendu de six si le dé est équitable :



Rejection thresholds

Seuils de rejet

143 or fewer is very few; 190 or more is very many:

143 ou moins, c'est très peu ; 190 ou plus, c'est très nombreux :

```
c(lower = pbinom(143, 1000, 1 / 6), upper = 1 - pbinom(189, 1000, 1 / 6))
```

lower	upper
0.02302647	0.02785689

Step 2: power

Étape 2 : puissance

What is the power?

Now stipulate how the world **really** works — not the null you plan to reject.

Suppose sixes actually appear **20%** of the time.

What is the probability of seeing at least 190 sixes?

```
1 - pbinom(189, 1000, .2)
```

```
[1] 0.796066
```

If sixes appear 20% of the time, you will likely see 190 sixes and reject “fair die.”

Quelle est la puissance ?

Maintenant, décrire comment le monde **fonctionne vraiment** — pas l'hypothèse nulle que l'on compte rejeter.

Supposons que les six sortent **20 %** du temps. Quelle est la probabilité d'observer au moins 190 six ?

Si les six sortent 20 % du temps, vous verrez probablement 190 six et rejeterez « dé équitable ».

Section 4

Interpretations

Rule of thumb

Règle empirique

- **80%** or **90%** is a common rule of thumb for “sufficient” power.
 - How much you need depends on the purpose.
- **80 %** ou **90 %** est une règle empirique courante pour une puissance « suffisante ».
 - Le besoin réel dépend de l'objectif.

Think about

À réfléchir

- Are there other tests you could implement?
- Are there other ways to improve this test?
- D'autres tests seraient-ils possibles ?
- D'autres façons d'améliorer ce test ?

Subtleties (1)

Subtilités (1)

- Is a significant result from an underpowered study less credible? (Only with a significance filter.)
- What significance level for power analysis? (Use what you will use in practice — stricter → lower power.)
- Un résultat significatif d'une étude sous-puissante est-il moins crédible ? (Seulement avec un filtre de significativité.)
- Quel niveau de significativité pour l'analyse de puissance ? (Celui que vous utiliserez — un plus strict → moins de puissance.)

Subtleties (2)

Subtilités (2)

- Must you know the effect size? (No — but know what sizes you want to detect.)
 - Power is one of many **diagnosands**.
 - What's power for Bayesians?
- Faut-il connaître la taille d'effet ? (Non — mais savoir quelles tailles vous voulez détecter.)
 - La puissance n'est qu'un **diagnosande** parmi d'autres.
 - Et la puissance pour les bayésiens ?

Section 5

Power analytics

Back to experiments

Retour aux expériences

- If we run an experiment we get an estimate b
 - We form beliefs about a distribution of estimates b (sampling distribution)
 - We also can think about the distribution of estimates we might get if there were no effect (the null distribution)
 - Just like with the dice!
- Si nous menons une expérience, nous obtenons une estimation b
 - Nous formons des croyances sur une distribution des estimations b (distribution d'échantillonnage)
 - Nous pouvons aussi penser à la distribution des estimations que nous pourrions obtenir s'il n'y avait pas d'effet (la distribution nulle)
 - Comme avec le dé !

If the sampling distribution is centered on b with standard error 1, what is the probability of a significant estimate?

- Below -1.96 : $F(-1.96 \mid \tau)$
- Above $+1.96$: $1 - F(1.96 \mid \tau)$

Add them: probability above 1.96 or below -1.96 .

Si la distribution d'échantillonnage est centrée sur b avec erreur-type 1, quelle est la probabilité d'une estimation significative ?

- En dessous de -1.96 : $F(-1.96 \mid \tau)$
- Au-dessus de $+1.96$: $1 - F(1.96 \mid \tau)$

Sommez : probabilité au-dessus de 1,96 ou en dessous de -1.96 .

Simple intuition

Intuition simple

```
power <- function(b, alpha = 0.05, critical = qnorm(1 - alpha / 2)) {  
  1 - pnorm(critical, mean = abs(b)) + pnorm(-critical, mean = abs(b))  
}
```

```
power(0)
```

```
[1] 0.05
```

```
power(1.96)
```

```
[1] 0.5000586
```

```
power(-1.96)
```

```
[1] 0.5000586
```

```
power(3)
```

```
[1] 0.8508388
```

Graph: effect 1.96

Graphique : effet 1,96

This is what `pwrss::power.z.test` does — with nice graphs.

If the true effect were 1.96, what would power be?


C'est ce que fait `pwrss::power.z.test` — avec de jolis graphiques.

Si l'effet vrai valait 1,96, quelle serait la puissance ?

```
pwrss::power.z.test(  
  mean = 1.96, alpha = 0.05,  
  alternative = "two.sided", plot = TRUE, verbose = FALSE  
)
```

Graph: effect 1.96

Graphique : effet 1,96



Graph: interpretation

Graphique : interprétation

Substantively: if an estimate is **just** significant on average, power is **50%**.

Substantiellement : si une estimation est **à peine** significative en moyenne, la puissance est de **50 %**.


Graph: effect 2.5

Graphique : effet 2,5

If the effect were 2.5 — is that a lot?

Si l'effet valait 2,5 — est-ce beaucoup ?

```
pwrss::power.z.test(  
  mean = 2.5, alpha = 0.05,  
  alternative = "two.sided", plot = TRUE, verbose = FALSE  
)
```




Graph: effect 2.5

Graphique : effet 2,5

If the effect were 0 — do we have any power?

Si l'effet valait 0 — est-ce que nous aurions de la puissance ?

```
pwrss::power.z.test(  
  mean = 0, alpha = 0.05,  
  alternative = "two.sided", plot = TRUE, verbose = FALSE  
)
```



Section 6

with Math and functions

Trial: standard error

Essai : erreur-type

Standard error depends on N and outcome variance σ .

With N subjects in two equal groups:

$$Var(\tau) = \frac{\sigma^2}{N/2} + \frac{\sigma^2}{N/2} = 4\frac{\sigma^2}{N}$$

$$\sigma_\tau = \frac{2\sigma}{\sqrt{N}}$$

(Tests use an **estimated** standard error.)

L'erreur-type dépend de N et de la variance σ .
Avec N sujets en deux groupes égaux :

$$Var(\tau) = \frac{\sigma^2}{N/2} + \frac{\sigma^2}{N/2} = 4\frac{\sigma^2}{N}$$

$$\sigma_\tau = \frac{2\sigma}{\sqrt{N}}$$

(Les tests utilisent une erreur-type **estimée**.)

Trial: power by hand

Essai : puissance à la main

```
se <- function(sd, N) (N / (N - 1))^.5 * 2 * sd / (N^.5)
```

```
power_2 <- function(  
  b, alpha = .05, sd = 1, N = 100,  
  critical = qnorm(1 - alpha / 2), se = 2 * sd / N^.5  
) {  
  1 - pnorm(critical, mean = abs(b) / se(sd, N)) +  
    pnorm(-critical, mean = abs(b) / se(sd, N))  
}
```

```
power_2(0)
```

```
[1] 0.05
```

```
power_2(.5)
```

```
[1] 0.7010827
```

Trial: with pwrss

Essai : avec pwrss

Same idea with pwrss:

Même idée avec pwrss :

```
pwrss::pwrss.t.2means(  
  mu1 = .2, mu2 = .1, sd1 = 1, sd2 = 1, n2 = 50, alpha = 0.05,  
  alternative = "not equal", verbose = FALSE  
)  
  
power_2(.50, N = 100)
```

```
[1] 0.7010827
```

Cluster RCT

ESS randomisé par grappes

Mostly: figure out the standard error.

Cluster shock ϵ_k , individual shock ν_i with variances σ_k^2 , σ_i^2 :

En pratique : calculer l'erreur-type.

Choc de grappe ϵ_k , choc individuel ν_i avec variances σ_k^2 , σ_i^2 :

$$\sqrt{\frac{4\sigma_k^2}{K} + \frac{4\sigma_i^2}{nK}}$$

With $\rho = \frac{\sigma_k^2}{\sigma_k^2 + \sigma_i^2}$:

$$\sqrt{((n-1)\rho + 1) \frac{4\sigma^2}{nK}}$$

- $((n-1)\rho + 1) =$ **design effect**
- $\frac{nK}{((n-1)\rho + 1)} =$ **effective sample size**

Plug in and proceed as before.

- $((n-1)\rho + 1) =$ **effet de conception**
- $\frac{nK}{((n-1)\rho + 1)} =$ **taille d'échantillon effective**

Insérez dans le calcul et procédez comme avant.

Section 7

Power via diagnosis

A design

Un design

A design in which you choose how many clusters you have!

```
N <- 100
b <- 0.5
n_clusters <- 50

design <-
  declare_model(
    N = N,
    U = rnorm(N),
    potential_outcomes(Y ~ b * Z + U),
    clusters = cut(rank(U), n_clusters, labels = 1:n_clusters)
  ) +
  declare_assignment(
    Z = cluster_ra(clusters = clusters),
    Y = reveal_outcomes(Y ~ Z)
  ) +
  declare_inquiry(ate = mean(Y_Z_1 - Y_Z_0)) +
  declare_estimator(Y ~ Z, inquiry = "ate", clusters = clusters)
```

Design diagnosis is **arbitrarily flexible**.

Le diagnostic de conception est **arbitrairement flexible**.

Simulate many times

Simuler plusieurs fois

```
sims_1 <- simulate_design(design)
sims_1 |> select(sim_ID, estimate, p.value)
```


sim_ID	estimate	p.value
1	0.73	0.02
2	0.67	0.03
3	0.78	0.01
4	0.66	0.02
5	0.38	0.19
6	1.32	0.00

Power: p -value distribution

Puissance : distribution des p

Power is the mass of the sampling distribution of **decisions** under the model.

La puissance est la masse de la distribution d'échantillonnage des **décisions** sous le modèle.




Estimates and significance

Estimations et significativité

Closely related to the estimates you might get:

Étroitement lié aux estimations possibles :



Coverage check

Vérifier la couverture

```
sims_1 |>  
  mutate(within = (b > sims_1$conf.low) & (b < sims_1$conf.high)) |>  
  pull(within) |>  
  mean()
```

```
[1] 0.955
```


Valid p -values

p -values valides

A valid p -value satisfies $\Pr(p \leq x) \leq x$ for every $x \in [0, 1]$ **under the null**.

Une p -value valide satisfait $\Pr(p \leq x) \leq x$ pour tout $x \in [0, 1]$ **sous l'hypothèse nulle**.

```
sims_2 <- redesign(design, b = 0) |> simulate_design()
```



`diagnose_design()`

`diagnose_design()`

```
diagnose_design(design)
```

Mean Estimate	Bias	SD Estimate	RMSE	Power	Coverage
0.50 (0.01)	0.00 (0.01)	0.28 (0.01)	0.28 (0.01)	0.41 (0.02)	0.95 (0.01)

Multiple effect sizes

Plusieurs tailles d'effet


```
design |>  
  redesign(b = c(0, 0.5, 1), n_clusters = c(5, 10, 50)) |>  
  diagnose_design()
```

b	n_clusters	Mean Estimate	Bias	SD Estimate	RMSE	Power	Coverage
0	5	-0.00 (0.07)	-0.00 (0.07)	0.95 (0.03)	0.95 (0.03)	0.00 (0.00)	1.00 (0.00)
0.5	5	0.47 (0.07)	-0.03 (0.07)	1.07 (0.04)	1.07 (0.04)	0.03 (0.01)	1.00 (0.00)
1	5	1.04 (0.07)	0.04 (0.07)	1.01 (0.03)	1.01 (0.03)	0.13 (0.03)	1.00 (0.00)
0	10	-0.05 (0.04)	-0.05 (0.04)	0.64 (0.03)	0.64 (0.03)	0.06 (0.02)	0.94 (0.02)
0.5	10	0.49 (0.05)	-0.01 (0.05)	0.67 (0.03)	0.67 (0.03)	0.07 (0.02)	0.96 (0.01)
1	10	1.04 (0.05)	0.04 (0.05)	0.67 (0.03)	0.67 (0.03)	0.26 (0.04)	0.94 (0.02)
0	50	0.01 (0.01)	0.01 (0.01)	0.31 (0.02)	0.31 (0.02)	0.03 (0.01)	0.93 (0.01)

Power over $n_clusters$ and b

Puissance selon $n_clusters$ et b

```
diagnosis |> tidy() |>  
  filter(diagnosand == "power") |>  
  ggplot(aes(b, estimate, color = factor(n_clusters))) +  
  geom_line()
```



Section 8

Takeaways

Big takeaways

Messages clés

- Power depends on sample size, variability, effect size — **and** data and analysis strategies.
 - Estimate power under **multiple scenarios**.
 - Use the **same code** for power as for your final analysis.
 - If you can declare a design and have a test, you can calculate power.
- La puissance dépend de N , de la variabilité, de la taille d'effet — **et** des stratégies de données et d'analyse.
 - Estimez la puissance sous **plusieurs scénarios**.
 - Utilisez le **même code** pour la puissance et l'analyse finale.
 - Si vous pouvez déclarer une conception et tester, vous pouvez calculer la puissance.

Big takeaways (2)

Messages clés (2)

- Power can be right but **misleading**. For confidence:
 - check **bias** and **coverage**, not just power
 - check power especially **under the null**
- Don't let power distract from more **substantive** diagnosands.
- La puissance peut être correcte mais **trompeuse**. Pour être sûr :
 - vérifiez **biais** et **couverture**, pas seulement la puissance
 - vérifiez la puissance surtout **sous l'hypothèse nulle**
- Ne laissez pas la puissance masquer des diagnosandes plus **substantiels**.