

R Session 1: Fundamentos

EGAP Latin America Hub Learning Days

26 August 2024

Bienvenidos a R! En esta primera actividad, les ayudaremos a tener una idea del análisis de datos básicos en R

Objetivos: aprender a cargar datos, inspeccionar los datos para ver qué variables hay y realizar resúmenes básicos de datos

Ejercicio 1: Empezando

Directorio de trabajo

El primer paso es definir la carpeta en donde vamos a estar trabajando, para esto usamos el comando `setwd()`

```
setwd("/Users/martinvanegas/Library/CloudStorage/Dropbox/Research/EGAP")
```

En esta carpeta es en donde deberían de tener los datos con los que vamos a trabajar. Para revisar el directorio usamos `dir()`

```
dir()
```

Pregunta 1: ¿El archivo de datos con el que trabajamos está en la lista que devolvió la función?

Ejercicio 2: Importando los datos

Importar la base de datos

R leerá el archivo y luego lo agregará como un objeto a su “espacio de trabajo” donde podemos analizarlo.

```
experiment_data <- read.csv("data_for_analysis.csv")
```

Podemos hacer esto a través de la función `read_csv()`, que toma un nombre de archivo que proporciona y lee ese archivo y crea un objeto de datos R, llamado marco de datos.

Pregunta 2: encuentre la pestaña “entorno” en su ventana de RStudio. Pida ayuda a un instructor o a alguien a su lado si no lo ve. ¿Aparece el objeto llamado `experiment_data` en el entorno?

Ejercicio 3: Inspeccionar los datos

Tómese un momento para mirar los datos en sí

Para hacer esto, encuentre la pestaña Entorno y haga clic una vez en el objeto `experiment_data`. Esto abre el “visor de datos”. Este es siempre un buen lugar para empezar a ver qué hay en los datos.

	Name	Gender	HomeCountry	treatment	treatment_received	Timestamp	Score	state_of_world
1	Participant 1	F	USA	0	control	2022-11-14T05:55:35Z	0	5
2	Participant 2	F	Cote d'Ivoire	0	control	2022-11-14T05:55:44Z	0	4
3	Participant 3	M	Cote d'Ivoire	1	treatment	2022-11-14T05:49:28Z	0	8
4	Participant 4	F	Colombia	1	treatment	2022-11-14T05:49:38Z	0	6
5	Participant 5	M	Venezuela	0	control	2022-11-14T05:55:53Z	0	6
6	Participant 6	M	Cote d'Ivoire	0	control	2022-11-14T05:56:13Z	0	3
7	Participant 7	M	Colombia	1	treatment	2022-11-14T05:49:48Z	0	10
8	Participant 8	M	Colombia	0	control	2022-11-14T05:56:21Z	0	5
9	Participant 9	M	Venezuela	1	treatment	2022-11-14T05:50:05Z	0	6
10	Participant 10	M	Cote d'Ivoire	0	control	2022-11-14T05:56:39Z	0	2
11	Participant 11	F	Colombia	1	treatment	2022-11-14T05:50:16Z	0	5
12	Participant 12	M	Venezuela	1	treatment	2022-11-14T05:50:25Z	0	7
13	Participant 13	F	Colombia	0	control	2022-11-14T05:56:48Z	0	7
14	Participant 14	F	Venezuela	0	control	2022-11-14T05:56:58Z	0	4
15	Participant 15	M	Venezuela	0	control	2022-11-14T05:57:07Z	0	1
16	Participant 16	M	Nigeria	0	control	2022-11-14T05:57:17Z	0	6
17	Participant 17	F	USA	1	treatment	2022-11-14T05:50:37Z	0	6

Ejercicio 4: instalar el tidyverse y cargar paquetes

Un “paquete” en R es una colección de funciones (comandos), datos y documentación que es como un kit de herramientas

El tidyverse es una familia de paquetes que están diseñados para trabajar juntos.

1. Vamos a empezar por instalarlo.

```
install.packages("tidyverse")
```

2. Tiene que descargar, así que debe estar conectado al wifi.
(Esto puede llevar un tiempo si el internet es lento)
3. Ahora vamos a cargar el paquete tidyverse. Para hacer esto, utilizamos otra función `library()` que hace que todos los recursos del paquete estén disponibles para ti en tu sesión de R

```
library(tidyverse)
```

Ejercicio 5: modificar los datos

A continuación vamos a aprender cómo manipular, o modificar, un data frame

Esto es útil si quieres crear una nueva variable, o cambiar una variable existente. Vamos a manipular nuestro data frame modificándolo y luego escribiendo sobre el original

```
experiment_data %>%  
  mutate(coffee = 1,  
         tea = c(0,1,0,1,0,1,0,1,10,11,0,1,0,1,0,1,0,1,0,1,1,0,1),  
         colombian = if_else(HomeCountry == "Colombia", 1, 0))
```

Una vez que ejecutamos esas líneas de código vemos que hay nuevas columnas a la derecha llamadas coffee, tea, y ivoirien. Vuelvan a revisar la base de datos, ¿aparecen las columnas?

Para que esta nueva columna se guarde en nuestro conjunto de datos, también necesitamos escribir sobre el objeto de datos original

```
experiment_data <- experiment_data %>%  
  mutate(coffee = 1,  
         tea = c(0,1,0,1,0,1,0,1,10,11,0,1,0,1,0,1,0,1,0,1,0,1),  
         colombian = if_else(HomeCountry == "Colombia", 1, 0))
```

Una forma rápida de contar los valores de una variable es la función `count()`

Tome `experiment_data` y luego cuente los valores de la variable `coffee`

```
experiment_data %>% count(coffee)
experiment_data %>% count(tea)
experiment_data %>% count(colombian)
```


Pregunta 3: ¿Cuántas unidades toman cada valor en la variable tea?

¿Cuál es el resultado en la consola?

```
> experiment_data %>% count(coffee)
  coffee    n
1      1 24

> experiment_data %>% count(tea)
  tea    n
1    0 11
2    1 13

> experiment_data %>% count(colombian)
colombian    n
1          0 19
2          1  5
```

Volvamos al código

¿Qué significa el símbolo “%>%”?

Estos se llaman “pipes” y le dicen a R que siga trabajando en una secuencia de pasos. Puede leerlos como “y luego...” porque conducen a la siguiente acción que desea realizar

Ejercicio 6: resumir datos

Otra tarea común en el análisis de datos es resumir los datos

Es posible que desee conocer el valor promedio de una variable, el máximo o la varianza. R tiene otra función de envoltura poderosa para ayudarlo a calcular este tipo de estadísticas resumidas: `summarise()`.

Comencemos con un ejemplo: tomemos la media y la desviación estándar de la variable `tea`.

```
experiment_data %>%  
  summarise(mean(tea, na.rm = T),  
            sd(tea, na.rm = T))
```

Vemos que la media de tea es 0.54 y la desviación estándar es 0.51

```
> experiment_data %>%  
+   summarise(mean(tea, na.rm = T),  
+             sd(tea, na.rm = T))  
  mean(tea, na.rm = T) sd(tea, na.rm = T)  
1          0.5416667      0.5089774
```

Pregunta 4: ¿Cuáles son la media, el máximo y el mínimo de la variable colombiana?

Respuesta

```
> experiment_data %>%  
+   summarise(colombian_mean = mean(tea, na.rm = T),  
+             colombian_min = min(tea, na.rm = T),  
+             colombian_max = max(tea, na.rm = T))  
  colombian_mean colombian_min colombian_max  
1          0.5416667           0           1
```


Ejercicio 7: filtrar los datos

Lo último que aprenderemos ahora es cómo filtrar los datos, o mirar solo un subconjunto de las observaciones

Esto es útil si queremos saber algo sobre un subconjunto de las observaciones y se usa a menudo en combinación con summarise().

Comencemos filtrando por género para que solo estemos mirando a las participantes femeninas en el experimento.

```
experiment_data %>%  
  filter(Gender == "F")
```

Debería ver solo 10 de las 24 observaciones en el conjunto de datos que se imprimen, y todas tienen “F” en la variable Género. Este código ha “filtrado” los datos para que solo mantenga las observaciones donde Género == “F”.

```
> experiment_data %>%
+   filter(Gender == "F")
```

	Name	Gender	HomeCountry	treatment	treatment_received	Timestamp	Score	state_of_world	coffee	tea	colombian
1	Participant 1	F	USA	0	control	2022-11-14T05:55:35Z	0	5	1	0	0
2	Participant 2	F	Cote d'Ivoire	0	control	2022-11-14T05:55:44Z	0	4	1	1	0
3	Participant 4	F	Colombia	1	treatment	2022-11-14T05:49:38Z	0	6	1	1	1
4	Participant 11	F	Colombia	1	treatment	2022-11-14T05:50:16Z	0	5	1	0	1
5	Participant 13	F	Colombia	0	control	2022-11-14T05:56:48Z	0	7	1	0	1
6	Participant 14	F	Venezuela	0	control	2022-11-14T05:56:58Z	0	4	1	1	0
7	Participant 17	F	USA	1	treatment	2022-11-14T05:50:37Z	0	6	1	0	0
8	Participant 21	F	Nigeria	1	treatment	2022-11-14T05:51:10Z	0	8	1	0	0
9	Participant 23	F	USA	1	treatment	2022-11-14T05:52:15Z	0	4	1	0	0
10	Participant 24	F	USA	0	control	2022-11-14T05:57:39Z	0	3	1	1	0

También podemos usar `count()` y `summarise()` para ejecutar funciones de resumen solo en este grupo. Aquí es donde las “pipes” son realmente útiles.

Comencemos contando los valores de la variable té solo para las participantes *femeninas*

```
experiment_data %>%  
  filter(Gender == "F") %>%  
  count(tea)
```

Sigamos a calcular la media de té solo para *hombres*

```
experiment_data %>%  
  filter(Gender == "M") %>%  
  summarise(tea_mean = mean(tea, na.rm = T))
```