

Inferencia Causal

Learning Days, EGAP LatAm

Omar García-Ponce

George Washington University
garciaponce@gwu.edu

27 de julio de 2026

Santiago, Chile

Lo que quiero que se lleven de esta sesión

1. Un efecto causal no es una intuición: es una **comparación entre mundos posibles**.

Lo que quiero que se lleven de esta sesión

1. Un efecto causal no es una intuición: es una **comparación entre mundos posibles**.
2. Antes de hablar de datos o métodos, necesitamos definir el **estimando** (*estimand*).

Lo que quiero que se lleven de esta sesión

1. Un efecto causal no es una intuición: es una **comparación entre mundos posibles**.
2. Antes de hablar de datos o métodos, necesitamos definir el **estimando** (*estimand*).
3. La aleatorización resuelve un problema muy preciso: conviene saber **cuál** — y cuál no.

1. ¿Por qué importa la causalidad?

Por qué casi toda pregunta de política pública es contrafactual, y por qué ningún dato responde por sí solo.

1. ¿Por qué importa la causalidad?

Por qué casi toda pregunta de política pública es contrafactual, y por qué ningún dato responde por sí solo.

2. Resultados potenciales

La notación que convierte una intuición causal en una cantidad definida.

1. ¿Por qué importa la causalidad?

Por qué casi toda pregunta de política pública es contrafactual, y por qué ningún dato responde por sí solo.

2. Resultados potenciales

La notación que convierte una intuición causal en una cantidad definida.

3. Estimandos

Qué promedio exactamente queremos conocer — y por qué elegirlo es parte del diseño.

1. ¿Por qué importa la causalidad?

Por qué casi toda pregunta de política pública es contrafactual, y por qué ningún dato responde por sí solo.

2. Resultados potenciales

La notación que convierte una intuición causal en una cantidad definida.

3. Estimandos

Qué promedio exactamente queremos conocer — y por qué elegirlo es parte del diseño.

4. El puente hacia el diseño

Qué consigue la aleatorización y qué no.

¿Por qué importa la causalidad?

Casi toda pregunta de política pública es contrafactual

Ustedes no preguntan “¿qué pasó?”. Preguntan “¿qué habría pasado?”

Casi toda pregunta de política pública es contrafactual

Ustedes no preguntan “¿qué pasó?”. Preguntan “¿qué habría pasado?”

- ¿El programa de transferencias **redujo** la deserción escolar?

La deserción bajó. ¿Habría bajado igual sin el programa?

Casi toda pregunta de política pública es contrafactual

Ustedes no preguntan “¿qué pasó?”. Preguntan “¿qué habría pasado?”

- ¿El programa de transferencias **redujo** la deserción escolar?

La deserción bajó. ¿Habría bajado igual sin el programa?

- ¿La capacitación docente **mejoró** los aprendizajes?

Los puntajes subieron. ¿Y si no hubiéramos capacitado a nadie?

Casi toda pregunta de política pública es contrafactual

Ustedes no preguntan “¿qué pasó?”. Preguntan “¿qué habría pasado?”

- ¿El programa de transferencias **redujo** la deserción escolar?

La deserción bajó. ¿Habría bajado igual sin el programa?

- ¿La capacitación docente **mejoró** los aprendizajes?

Los puntajes subieron. ¿Y si no hubiéramos capacitado a nadie?

- ¿La presencia policial **disminuyó** los homicidios?

Se desplegó policía donde había más homicidios. ¿Comparado con qué?

Casi toda pregunta de política pública es contrafactual

Ustedes no preguntan “¿qué pasó?”. Preguntan “¿qué habría pasado?”

- ¿El programa de transferencias **redujo** la deserción escolar?

La deserción bajó. ¿Habría bajado igual sin el programa?

- ¿La capacitación docente **mejoró** los aprendizajes?

Los puntajes subieron. ¿Y si no hubiéramos capacitado a nadie?

- ¿La presencia policial **disminuyó** los homicidios?

Se desplegó policía donde había más homicidios. ¿Comparado con qué?

La pregunta interesante siempre es sobre un **mundo que no observamos**. La inferencia causal es el estudio disciplinado de esos mundos.

datos + supuestos = conclusiones

Manski (1995)

$$\text{datos} + \text{supuestos} = \text{conclusiones}$$

Manski (1995)

- Ningún conjunto de datos “habla por sí solo”. Los datos por sí mismos nunca identifican un efecto causal.

$$\text{datos} + \text{supuestos} = \text{conclusiones}$$

Manski (1995)

- Ningún conjunto de datos “habla por sí solo”. Los datos por sí mismos nunca identifican un efecto causal.
- Dos investigadores con **los mismos datos** y **distintos supuestos** llegan legítimamente a conclusiones distintas.

$$\text{datos} + \text{supuestos} = \text{conclusiones}$$

Manski (1995)

- Ningún conjunto de datos “habla por sí solo”. Los datos por sí mismos nunca identifican un efecto causal.
- Dos investigadores con **los mismos datos** y **distintos supuestos** llegan legítimamente a conclusiones distintas.
- Entonces la pregunta no es “¿*tienen supuestos?*” sino “¿**cuáles son y son defendibles?**”

No hay conclusión sin supuestos

$$\text{datos} + \text{supuestos} = \text{conclusiones}$$

Manski (1995)

- Ningún conjunto de datos “habla por sí solo”. Los datos por sí mismos nunca identifican un efecto causal.
- Dos investigadores con **los mismos datos** y **distintos supuestos** llegan legítimamente a conclusiones distintas.
- Entonces la pregunta no es “¿*tienen supuestos?*” sino “¿**cuáles son y son defendibles?**”

Lo que hace un buen diseño

Un buen diseño de investigación no elimina los supuestos: los vuelve **pocos, explícitos y discutibles**.

El lenguaje que usamos cuando no queremos comprometernos

Antes de la “revolución de la credibilidad”: regresión con todo lo disponible + palabras comodín.

“está asociado con”

“incide en”

“se vincula a”

“predice”

“contribuye a”

“es determinante de”

“influye sobre”

“explica la variación en”

“va de la mano con”

El lenguaje que usamos cuando no queremos comprometernos

Antes de la “revolución de la credibilidad”: regresión con todo lo disponible + palabras comodín.

“está asociado con”

“incide en”

“se vincula a”

“predice”

“contribuye a”

“es determinante de”

“influye sobre”

“explica la variación en”

“va de la mano con”

Son ambiguas y comunmente se leen como causales, pero son, fundamentalmente, descriptivas.

El lenguaje que usamos cuando no queremos comprometernos

Antes de la “revolución de la credibilidad”: regresión con todo lo disponible + palabras comodín.

“está asociado con”

“incide en”

“se vincula a”

“predice”

“contribuye a”

“es determinante de”

“influye sobre”

“explica la variación en”


“va de la mano con”

Son ambiguas y comunmente se leen como causales, pero son, fundamentalmente, descriptivas.

¿Cuál es el efecto de este programa frente a no tenerlo sobre este resultado?

La alternativa: un **estimando** explícito y un **diseño** que lo identifique.


Correlación no implica causalidad



Consumo de chocolate per cápita y premios Nobel por cada 10 millones de habitantes, 23 países.

Fuente: Messerli (2012), *New England Journal of Medicine*.

Correlación no implica causalidad




¿El chocolate nos hace más inteligentes?

Consumo de chocolate per cápita y premios Nobel por cada 10 millones de habitantes, 23 países.

Fuente: Messerli (2012), *New England Journal of Medicine*.

No: hay una tercera variable


La **riqueza nacional** impulsa *ambas* cosas: el consumo de chocolate y la inversión en educación y ciencia.



No: hay una tercera variable

La **riqueza nacional** impulsa *ambas* cosas: el consumo de chocolate y la inversión en educación y ciencia.

Una **variable de confusión** o **confusor** (*confounder*) es una variable que causa tanto el “tratamiento” como el resultado, y genera una asociación espuria.




No: hay una tercera variable

La **riqueza nacional** impulsa *ambas* cosas: el consumo de chocolate y la inversión en educación y ciencia.

Una **variable de confusión** o **confusor** (*confounder*) es una variable que causa tanto el “tratamiento” como el resultado, y genera una asociación espuria.

Noten que la correlación es **real**: $r = 0,791$. Lo que falla no es la medición, sino la **interpretación causal**.



... ¿o sí?

Una correlación **sí** identifica un efecto causal — cuando el proceso que asignó el tratamiento es independiente de los resultados potenciales.

Una correlación **sí** identifica un efecto causal — cuando el proceso que asignó el tratamiento es independiente de los resultados potenciales.

- El problema nunca fue la correlación. El problema es **de dónde vino la variación** en el tratamiento.


Una correlación **sí** identifica un efecto causal — cuando el proceso que asignó el tratamiento es independiente de los resultados potenciales.

- El problema nunca fue la correlación. El problema es **de dónde vino la variación** en el tratamiento.
- Si esa variación la produjo un sorteo, la diferencia de medias es el efecto causal promedio.

Una correlación **sí** identifica un efecto causal — cuando el proceso que asignó el tratamiento es independiente de los resultados potenciales.

- El problema nunca fue la correlación. El problema es **de dónde vino la variación** en el tratamiento.
- Si esa variación la produjo un sorteo, la diferencia de medias es el efecto causal promedio.
- Si la produjo la autoselección, la burocracia o la geografía, hay que **argumentar** por qué la comparación es válida.

La revolución de la credibilidad en datos




Proporción de artículos publicados que usan experimentos en las dos principales revistas de sociología, economía y ciencia política, 1990–2020. Fuente: Mize y Manago (2022).


Premios Nobel de Economía: **2019** Banerjee, Duflo y Kremer — **2021** Card, Angrist e Imbens.

Tendencias recientes en ciencia política

Los estudios empíricos basados en diseños que hacen explícita su estrategia de identificación han aumentado considerablemente durante las últimas dos décadas.



(a) Design-based vs. model-based studies



(b) Design-based studies by subfield

Estudios *basados en diseño* — los que explicitan su estrategia de identificación — frente a *basados en modelo*. 91.632 artículos, 174 revistas, 2003–2023. Fuente: Torreblanca, Dinneen, Grossman y Xu (2026).

Resultados potenciales

“X causó Y” es una afirmación sobre lo que *no* ocurrió

- En el enfoque contrafactual: “si X no hubiera ocurrido, Y no habría ocurrido”.

“X causó Y” es una afirmación sobre lo que *no* ocurrió

- En el enfoque contrafactual: “si X no hubiera ocurrido, Y no habría ocurrido”.
- No es la única forma de pensar la causalidad — pero ha sido extraordinariamente productiva.

“X causó Y” es una afirmación sobre lo que *no* ocurrió

- En el enfoque contrafactual: “si X no hubiera ocurrido, Y no habría ocurrido”.
- No es la única forma de pensar la causalidad — pero ha sido extraordinariamente productiva.
- Y tiene una virtud práctica: obliga a decir con qué se compara.

“X causó Y” es una afirmación sobre lo que *no* ocurrió

- En el enfoque contrafactual: “si X no hubiera ocurrido, Y no habría ocurrido”.
- No es la única forma de pensar la causalidad — pero ha sido extraordinariamente productiva.
- Y tiene una virtud práctica: obliga a decir *con qué se compara*.

Cuatro precisiones importantes

1. “X causa Y” *no* implica que W y V no causen Y. X es parte de la historia, no toda la historia.
2. “X causa Y” *requiere contexto*: un fósforo encendido causa la llama, pero necesita oxígeno (Cartwright y Hardie 2012).
3. *No* hace falta conocer el mecanismo para establecer que X causa Y.
4. “X causa Y” puede ser *probabilístico*: con X, Y es más probable. Sigue siendo contrafactual.

Un colega les dice: “hice el diplomado y a los tres meses me ascendieron — el diplomado me consiguió el ascenso”.

1. ¿Qué contrafactual está afirmando *implícitamente*?
2. ¿Qué *otros* contrafactuales serían compatibles con lo que observó?

La afirmación causal esconde un contrafactual específico

En este caso, la afirmación es: *“si no hubiera hecho el diplomado, no me habrían ascendido”*.

La afirmación causal esconde un contrafactual específico

En este caso, la afirmación es: *“si no hubiera hecho el diplomado, no me habrían ascendido”*.

Pero nuestro colega solo observó una de las historias/resultados posibles. Las otras son igual de compatibles con lo que vio:

La afirmación causal esconde un contrafactual específico

En este caso, la afirmación es: “*si no hubiera hecho el diplomado, no me habrían ascendido*”.

Pero nuestro colega **solo observó una de las historias/resultados posibles**. Las otras son igual de compatibles con lo que vio:

- “*... me habrían ascendido igual*” → **efecto nulo**

Le tocaba por antigüedad; o quien se inscribe a un diplomado ya es de los que iban a ascender.

La afirmación causal esconde un contrafactual específico

En este caso, la afirmación es: “*si no hubiera hecho el diplomado, no me habrían ascendido*”.

Pero nuestro colega **solo observó una de las historias/resultados posibles**. Las otras son igual de compatibles con lo que vio:

- “... *me habrían ascendido igual*” → **efecto nulo**
Le tocaba por antigüedad; o quien se inscribe a un diplomado ya es de los que iban a ascender.
- “... *me habrían ascendido antes*” → **efecto negativo**
Las horas del diplomado se las quitó al trabajo visible.

La afirmación causal esconde un contrafactual específico

En este caso, la afirmación es: “*si no hubiera hecho el diplomado, no me habrían ascendido*”.

Pero nuestro colega solo observó una de las historias/resultados posibles. Las otras son igual de compatibles con lo que vio:

- “... *me habrían ascendido igual*” → efecto nulo
Le tocaba por antigüedad; o quien se inscribe a un diplomado ya es de los que iban a ascender.
- “... *me habrían ascendido antes*” → efecto negativo
Las horas del diplomado se las quitó al trabajo visible.

Dos lecciones

- (a) Toda afirmación causal contiene un contrafactual oculto. Hacerlo explícito es el primer paso.
- (b) Con una observación de una persona no podemos distinguir entre estas tres historias. Necesitamos notación — y después, un diseño.

Resultados potenciales: la notación de Neyman–Rubin

Para cada unidad i y un tratamiento binario $D_i \in \{0, 1\}$:

- $Y_i(1)$: el resultado que *tendría* la unidad i **si recibiera** el tratamiento.
- $Y_i(0)$: el resultado que *tendría* la unidad i **si no lo recibiera**.

Resultados potenciales: la notación de Neyman–Rubin

Para cada unidad i y un tratamiento binario $D_i \in \{0, 1\}$:

- $Y_i(1)$: el resultado que *tendría* la unidad i **si recibiera** el tratamiento.
- $Y_i(0)$: el resultado que *tendría* la unidad i **si no lo recibiera**.

Los dos existen **para cada unidad**, *antes* de que se asigne nada. Uno de ellos será real; el otro, contrafactual.

Resultados potenciales: la notación de Neyman–Rubin

Para cada unidad i y un tratamiento binario $D_i \in \{0, 1\}$:

- $Y_i(1)$: el resultado que *tendría* la unidad i **si recibiera** el tratamiento.
- $Y_i(0)$: el resultado que *tendría* la unidad i **si no lo recibiera**.

Los dos existen **para cada unidad**, *antes* de que se asigne nada. Uno de ellos será real; el otro, contrafactual.

El puente entre lo potencial y lo observado

$$Y_i = D_i Y_i(1) + (1 - D_i) Y_i(0) \quad \text{es decir} \quad Y_i = Y_i(D_i)$$

Observamos el resultado potencial que corresponde al tratamiento que la unidad efectivamente recibió — y **solo ese**.

El efecto causal es una resta

$$\tau_i = Y_i(1) - Y_i(0)$$

El efecto causal es una resta

$$\tau_i = Y_i(1) - Y_i(0)$$

- Es el efecto causal **de esa unidad**, no de un promedio ni de un grupo.

El efecto causal es una resta

$$\tau_i = Y_i(1) - Y_i(0)$$

- Es el efecto causal **de esa unidad**, no de un promedio ni de un grupo.
- Cada unidad tiene el suyo: los efectos son **heterogéneos** por construcción.

El efecto causal es una resta

$$\tau_i = Y_i(1) - Y_i(0)$$

- Es el efecto causal **de esa unidad**, no de un promedio ni de un grupo.
- Cada unidad tiene el suyo: los efectos son **heterogéneos** por construcción.
- Nótese que τ_i **no depende** de cómo se asignó el tratamiento. Es una propiedad de la unidad y del mundo, no del estudio.

El efecto causal es una resta

$$\tau_i = Y_i(1) - Y_i(0)$$

- Es el efecto causal **de esa unidad**, no de un promedio ni de un grupo.
- Cada unidad tiene el suyo: los efectos son **heterogéneos** por construcción.
- Nótese que τ_i **no depende** de cómo se asignó el tratamiento. Es una propiedad de la unidad y del mundo, no del estudio.

Una convención de notación

Usamos D (o T) para el **tratamiento** cuyo efecto queremos conocer, y X para **covariables** medidas antes del tratamiento.

El problema fundamental de la inferencia causal

Ejemplo clásico: campaña puerta a puerta (D_i) y participación electoral (Y_i).

Votante i	Edad X_i	Campaña D_i	Resultados potenciales $Y_i(1)$ $Y_i(0)$		Efecto causal $Y_i(1) - Y_i(0)$
1	25	1	0	???	???
2	38	0	???	1	???
3	67	0	???	1	???
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
n	43	1	1	???	???

El problema fundamental de la inferencia causal

Ejemplo clásico: campaña puerta a puerta (D_i) y participación electoral (Y_i).

Votante i	Edad X_i	Campaña D_i	Resultados potenciales $Y_i(1)$ $Y_i(0)$		Efecto causal $Y_i(1) - Y_i(0)$
1	25	1	0	???	???
2	38	0	???	1	???
3	67	0	???	1	???
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
n	43	1	1	???	???

La columna que nos interesa está **completamente vacía**.

El problema es, fundamentalmente, un problema de datos faltantes

Holland (1986)

Es **imposible** observar $Y_i(1)$ y $Y_i(0)$ para la misma unidad. Por lo tanto, el efecto causal individual τ_i **nunca** es observable.

El problema es, fundamentalmente, un problema de datos faltantes

Holland (1986)

Es **imposible** observar $Y_i(1)$ y $Y_i(0)$ para la misma unidad. Por lo tanto, el efecto causal individual τ_i **nunca** es observable.

- La inferencia causal es, formalmente, un **problema de datos faltantes**. La mitad de la tabla no existe.

El problema es, fundamentalmente, un problema de datos faltantes

Holland (1986)

Es **imposible** observar $Y_i(1)$ y $Y_i(0)$ para la misma unidad. Por lo tanto, el efecto causal individual τ_i **nunca** es observable.

- La inferencia causal es, formalmente, un **problema de datos faltantes**. La mitad de la tabla no existe.
- No es un problema de tamaño de muestra: con un millón de observaciones seguimos sin ver ni un solo τ_i .

El problema es, fundamentalmente, un problema de datos faltantes

Holland (1986)

Es **imposible** observar $Y_i(1)$ y $Y_i(0)$ para la misma unidad. Por lo tanto, el efecto causal individual τ_i **nunca** es observable.

- La inferencia causal es, formalmente, un **problema de datos faltantes**. La mitad de la tabla no existe.
- No es un problema de tamaño de muestra: con un millón de observaciones seguimos sin ver ni un solo τ_i .
- Y no es un problema que se resuelva con mejores datos, sino con **supuestos** — que un buen diseño hace creíbles.

El problema es, fundamentalmente, un problema de datos faltantes

Holland (1986)

Es **imposible** observar $Y_i(1)$ y $Y_i(0)$ para la misma unidad. Por lo tanto, el efecto causal individual τ_i **nunca** es observable.

- La inferencia causal es, formalmente, un **problema de datos faltantes**. La mitad de la tabla no existe.
- No es un problema de tamaño de muestra: con un millón de observaciones seguimos sin ver ni un solo τ_i .
- Y no es un problema que se resuelva con mejores datos, sino con **supuestos** — que un buen diseño hace creíbles.

Estrategia: renunciar a τ_i y buscar promedios que *sí* sean identificables.

Lo que esta definición nos obliga a precisar

1. Hay que definir la condición de control.

Si $D = 1$ es una asamblea comunitaria sobre salud pública, ¿ $D = 0$ es *ninguna* asamblea?
¿Una asamblea sobre otro tema? ¿Un volante?

“El efecto de D sobre Y ” no significa nada sin decir qué es no tener D .

Lo que esta definición nos obliga a precisar

1. Hay que definir la condición de control.

Si $D = 1$ es una asamblea comunitaria sobre salud pública, ¿ $D = 0$ es *ninguna* asamblea?

¿Una asamblea sobre otro tema? ¿Un volante?

“El efecto de D sobre Y ” no significa nada sin decir qué es no tener D .

2. Hay que definir la unidad. ¿Persona, hogar, escuela, municipio? El efecto sobre las escuelas no es el efecto sobre los estudiantes.

Lo que esta definición nos obliga a precisar

1. Hay que definir la condición de control.

Si $D = 1$ es una asamblea comunitaria sobre salud pública, ¿ $D = 0$ es *ninguna* asamblea?
¿Una asamblea sobre otro tema? ¿Un volante?

“El efecto de D sobre Y ” no significa nada sin decir qué es no tener D .

2. Hay que definir la unidad. ¿Persona, hogar, escuela, municipio? El efecto sobre las escuelas no es el efecto sobre los estudiantes.

3. Hay que definir cuándo se mide Y . El efecto al mes y el efecto a los dos años son estimandos distintos, no estimaciones distintas del mismo.

No hay causalidad sin manipulación

$Y_i(d)$ es el valor que tomaría Y si **fijáramos** $D_i = d$. Para que esté bien definido hace falta una **intervención bien definida** (*well-defined intervention*): el tratamiento debe poder aplicarse a la unidad **al menos en principio** (Holland 1986).

No hay causalidad sin manipulación

$Y_i(d)$ es el valor que tomaría Y si **fijáramos** $D_i = d$. Para que esté bien definido hace falta una **intervención bien definida** (*well-defined intervention*): el tratamiento debe poder aplicarse a la unidad **al menos en principio** (Holland 1986).

- ¿Cuál es “el efecto causal de **ser mujer**” sobre el salario?

No hay causalidad sin manipulación

$Y_i(d)$ es el valor que tomaría Y si **fijáramos** $D_i = d$. Para que esté bien definido hace falta una **intervención bien definida** (*well-defined intervention*): el tratamiento debe poder aplicarse a la unidad **al menos en principio** (Holland 1986).

- ¿Cuál es “el efecto causal de **ser mujer**” sobre el salario?
- ¿Cuál es “el efecto causal de **ser pobre**” sobre la participación política?

No hay causalidad sin manipulación

$Y_i(d)$ es el valor que tomaría Y si **fijáramos** $D_i = d$. Para que esté bien definido hace falta una **intervención bien definida** (*well-defined intervention*): el tratamiento debe poder aplicarse a la unidad **al menos en principio** (Holland 1986).

- ¿Cuál es “el efecto causal de **ser mujer**” sobre el salario?
- ¿Cuál es “el efecto causal de **ser pobre**” sobre la participación política?
- ¿Qué acto, exactamente, llevaría a esta unidad de $d = 0$ a $d = 1$? Si no lo podemos especificar, el estimando no está definido — y la pregunta, tal como está formulada, no es causal.

No hay causalidad sin manipulación

$Y_i(d)$ es el valor que tomaría Y si **fijáramos** $D_i = d$. Para que esté bien definido hace falta una **intervención bien definida** (*well-defined intervention*): el tratamiento debe poder aplicarse a la unidad **al menos en principio** (Holland 1986).

- ¿Cuál es “el efecto causal de **ser mujer**” sobre el salario?
- ¿Cuál es “el efecto causal de **ser pobre**” sobre la participación política?
- ¿Qué acto, exactamente, llevaría a esta unidad de $d = 0$ a $d = 1$? Si no lo podemos especificar, el estimando no está definido — y la pregunta, tal como está formulada, no es causal.

Especificar la intervención **es** definir la condición de control: son la misma operación, no dos requisitos. Sin condición de control no hay $Y_i(0)$, y sin $Y_i(0)$ no hay resta. El efecto no es difícil de estimar: **no existe**.

Qué hacer con los atributos no manipulables

Reformular la pregunta en términos de algo que **sí** se pueda intervenir:

- “El efecto del género” → el efecto de la **percepción** de género: currículums (CV) idénticos con nombre de mujer o de hombre.

Qué hacer con los atributos no manipulables

Reformular la pregunta en términos de algo que **sí** se pueda intervenir:

- “El efecto del género” → el efecto de la **percepción** de género: currículums (CV) idénticos con nombre de mujer o de hombre.
- “El efecto del origen étnico” → el efecto del **nombre** en una solicitud de vivienda o de empleo.

Qué hacer con los atributos no manipulables

Reformular la pregunta en términos de algo que **sí** se pueda intervenir:

- “El efecto del género” → el efecto de la **percepción** de género: currículums (CV) idénticos con nombre de mujer o de hombre.
- “El efecto del origen étnico” → el efecto del **nombre** en una solicitud de vivienda o de empleo.
- “El efecto de la pobreza” → el efecto de una **transferencia monetaria**.

Qué hacer con los atributos no manipulables

Reformular la pregunta en términos de algo que **sí** se pueda intervenir:

- “El efecto del género” → el efecto de la **percepción** de género: currículums (CV) idénticos con nombre de mujer o de hombre.
- “El efecto del origen étnico” → el efecto del **nombre** en una solicitud de vivienda o de empleo.
- “El efecto de la pobreza” → el efecto de una **transferencia monetaria**.
- “El efecto de la corrupción” → el efecto de **informar** a los votantes sobre la corrupción de su alcalde.

Qué hacer con los atributos no manipulables

Reformular la pregunta en términos de algo que **sí** se pueda intervenir:

- “El efecto del género” → el efecto de la **percepción** de género: currículums (CV) idénticos con nombre de mujer o de hombre.
- “El efecto del origen étnico” → el efecto del **nombre** en una solicitud de vivienda o de empleo.
- “El efecto de la pobreza” → el efecto de una **transferencia monetaria**.
- “El efecto de la corrupción” → el efecto de **informar** a los votantes sobre la corrupción de su alcalde.

Además

Los atributos no manipulables siguen siendo utilísimos como **covariables**: para armar bloques en la aleatorización (*blocking*), para describir la muestra y para estudiar **heterogeneidad** de efectos. Lo que no pueden ser es el tratamiento.

Estimandos

Del efecto individual al efecto promedio

No podemos identificar τ_i . Pero sí podemos aspirar a su promedio:

$$\text{ATE} = \mathbb{E}[Y_i(1) - Y_i(0)] \qquad \text{SATE} = \frac{1}{n} \sum_{i=1}^n [Y_i(1) - Y_i(0)] = \overline{Y(1)} - \overline{Y(0)}$$

Del efecto individual al efecto promedio

No podemos identificar τ_i . Pero sí podemos aspirar a su promedio:

$$\text{ATE} = \mathbb{E}[Y_i(1) - Y_i(0)] \qquad \text{SATE} = \frac{1}{n} \sum_{i=1}^n [Y_i(1) - Y_i(0)] = \overline{Y(1)} - \overline{Y(0)}$$

- **Efecto promedio del tratamiento** (*average treatment effect*): el resultado promedio si *todos* recibieran el tratamiento, menos el promedio si *nadie* lo recibiera.

Del efecto individual al efecto promedio

No podemos identificar τ_i . Pero sí podemos aspirar a su promedio:

$$\text{ATE} = \mathbb{E}[Y_i(1) - Y_i(0)] \qquad \text{SATE} = \frac{1}{n} \sum_{i=1}^n [Y_i(1) - Y_i(0)] = \overline{Y(1)} - \overline{Y(0)}$$

- **Efecto promedio del tratamiento** (*average treatment effect*): el resultado promedio si *todos* recibieran el tratamiento, menos el promedio si *nadie* lo recibiera.
- La versión de muestra finita (SATE) es el promedio *en su estudio*; la versión con valor esperado (ATE) es el promedio *en la población*. No son lo mismo.

Del efecto individual al efecto promedio

No podemos identificar τ_i . Pero sí podemos aspirar a su promedio:

$$\text{ATE} = \mathbb{E}[Y_i(1) - Y_i(0)] \qquad \text{SATE} = \frac{1}{n} \sum_{i=1}^n [Y_i(1) - Y_i(0)] = \overline{Y(1)} - \overline{Y(0)}$$

- **Efecto promedio del tratamiento** (*average treatment effect*): el resultado promedio si *todos* recibieran el tratamiento, menos el promedio si *nadie* lo recibiera.
- La versión de muestra finita (SATE) es el promedio *en su estudio*; la versión con valor esperado (ATE) es el promedio *en la población*. No son lo mismo.
- La clave algebraica que lo hace alcanzable: **el promedio de las diferencias es igual a la diferencia de los promedios**. Y los promedios sí los podremos estimar — bajo un supuesto que veremos en un momento.

Del efecto individual al efecto promedio

No podemos identificar τ_i . Pero sí podemos aspirar a su promedio:

$$\text{ATE} = \mathbb{E}[Y_i(1) - Y_i(0)] \qquad \text{SATE} = \frac{1}{n} \sum_{i=1}^n [Y_i(1) - Y_i(0)] = \overline{Y(1)} - \overline{Y(0)}$$

- **Efecto promedio del tratamiento** (*average treatment effect*): el resultado promedio si *todos* recibieran el tratamiento, menos el promedio si *nadie* lo recibiera.
- La versión de muestra finita (SATE) es el promedio *en su estudio*; la versión con valor esperado (ATE) es el promedio *en la población*. No son lo mismo.
- La clave algebraica que lo hace alcanzable: **el promedio de las diferencias es igual a la diferencia de los promedios**. Y los promedios sí los podremos estimar — bajo un supuesto que veremos en un momento.
- Ojo: un ATE de cero **no** significa que el tratamiento no hizo nada. Puede haber efectos positivos y negativos que se cancelan.

Otros estimandos que quizá les interesen más

- **ATT** — efecto promedio *sobre los tratados*: $\mathbb{E}[Y_i(1) - Y_i(0) \mid D_i = 1]$.
Útil cuando el programa ya existe y la pregunta es si conviene mantenerlo.

Otros estimandos que quizá les interesen más

- **ATT** — efecto promedio *sobre los tratados*: $\mathbb{E}[Y_i(1) - Y_i(0) \mid D_i = 1]$.
Útil cuando el programa ya existe y la pregunta es si conviene mantenerlo.
- **ATU** — efecto promedio *sobre los no tratados*: $\mathbb{E}[Y_i(1) - Y_i(0) \mid D_i = 0]$.
El número que decide una *expansión* de programa — y el que casi nadie reporta.
- **CATE** — efecto promedio *condicionado* a las covariables: $\mathbb{E}[Y_i(1) - Y_i(0) \mid X_i = x]$.
Para focalizar: ¿a quién conviene tratar? Hay que planificarlo de antemano.

Otros estimandos que quizá les interesen más

- **ATT** — efecto promedio *sobre los tratados*: $\mathbb{E}[Y_i(1) - Y_i(0) \mid D_i = 1]$.
Útil cuando el programa ya existe y la pregunta es si conviene mantenerlo.
- **ATU** — efecto promedio *sobre los no tratados*: $\mathbb{E}[Y_i(1) - Y_i(0) \mid D_i = 0]$.
El número que decide una *expansión* de programa — y el que casi nadie reporta.
- **CATE** — efecto promedio *condicionado* a las covariables: $\mathbb{E}[Y_i(1) - Y_i(0) \mid X_i = x]$.
Para focalizar: ¿a quién conviene tratar? Hay que planificarlo de antemano.
- **ITT** — efecto de *ofrecer* el tratamiento, se tome o no.
Si participar es voluntario, ¿cuál es el efecto de *ofrecer* el programa?

Otros estimandos que quizá les interesen más

- **ATT** — efecto promedio *sobre los tratados*: $\mathbb{E}[Y_i(1) - Y_i(0) \mid D_i = 1]$.
Útil cuando el programa ya existe y la pregunta es si conviene mantenerlo.
- **ATU** — efecto promedio *sobre los no tratados*: $\mathbb{E}[Y_i(1) - Y_i(0) \mid D_i = 0]$.
El número que decide una *expansión* de programa — y el que casi nadie reporta.
- **CATE** — efecto promedio *condicionado* a las covariables: $\mathbb{E}[Y_i(1) - Y_i(0) \mid X_i = x]$.
Para focalizar: ¿a quién conviene tratar? Hay que planificarlo de antemano.
- **ITT** — efecto de *ofrecer* el tratamiento, se tome o no.
Si participar es voluntario, ¿cuál es el efecto de *ofrecer* el programa?
- **LATE** — efecto sobre quienes *cambian su participación en el tratamiento como resultado de la asignación* (los “cumplidores”).
El estimando de los diseños de estímulo (encouragement) y de variables instrumentales. La regresión discontinua también captura un efecto local (al umbral).

Un mismo programa, cinco preguntas distintas

Programa de capacitación docente. Un solo experimento; Y = aprendizajes de los estudiantes.

La pregunta de quien decide	Estimando
-----------------------------	-----------

¿Capacitamos a <i>todos</i> los docentes del sistema?	ATE
---	-----

Un mismo programa, cinco preguntas distintas

Programa de capacitación docente. Un solo experimento; Y = aprendizajes de los estudiantes.

La pregunta de quien decide	Estimando
¿Capacitamos a <i>todos</i> los docentes del sistema?	ATE
¿Mantenemos el programa para las escuelas que <i>ya están</i> ?	ATT

Un mismo programa, cinco preguntas distintas

Programa de capacitación docente. Un solo experimento; Y = aprendizajes de los estudiantes.

La pregunta de quien decide	Estimando
¿Capacitamos a <i>todos</i> los docentes del sistema?	ATE
¿Mantenemos el programa para las escuelas que <i>ya están</i> ?	ATT
¿Lo <i>expandimos</i> a las escuelas que hoy no participan?	ATU

Un mismo programa, cinco preguntas distintas

Programa de capacitación docente. Un solo experimento; Y = aprendizajes de los estudiantes.

La pregunta de quien decide	Estimando
¿Capacitamos a <i>todos</i> los docentes del sistema?	ATE
¿Mantenemos el programa para las escuelas que <i>ya están</i> ?	ATT
¿Lo <i>expandimos</i> a las escuelas que hoy no participan?	ATU
¿Dónde tiene mejores resultados? en escuelas rurales o urbanas?	CATE

Un mismo programa, cinco preguntas distintas

Programa de capacitación docente. Un solo experimento; Y = aprendizajes de los estudiantes.

La pregunta de quien decide	Estimando
¿Capacitamos a <i>todos</i> los docentes del sistema?	ATE
¿Mantenemos el programa para las escuelas que <i>ya están</i> ?	ATT
¿Lo <i>expandimos</i> a las escuelas que hoy no participan?	ATU
¿Dónde tiene mejores resultados? en escuelas rurales o urbanas?	CATE
Si asistir es voluntario, ¿qué efecto tiene <i>ofrecerla</i> ?	ITT

Un mismo programa, cinco preguntas distintas

Programa de capacitación docente. Un solo experimento; Y = aprendizajes de los estudiantes.

La pregunta de quien decide	Estimando
¿Capacitamos a <i>todos</i> los docentes del sistema?	ATE
¿Mantenemos el programa para las escuelas que <i>ya están</i> ?	ATT
¿Lo <i>expandimos</i> a las escuelas que hoy no participan?	ATU
¿Dónde tiene mejores resultados? en escuelas rurales o urbanas?	CATE
Si asistir es voluntario, ¿qué efecto tiene <i>ofrecerla</i> ?	ITT

Un mismo experimento puede estimar varias. **Cuál era la principal se decide antes** — no después de ver los resultados.

¿Cuál es el efecto de [tratamiento] frente a [condición de control]
sobre [resultado], medido en [momento],
en [población]?

Elegir el estimando es parte del diseño

¿Cuál es el efecto de [tratamiento] frente a [condición de control]
sobre [resultado], medido en [momento],
en [población]?

En notación: $\mathbb{E}[Y_i(1) - Y_i(0)]$, donde $D_i = 1$ es el tratamiento y $D_i = 0$ es la condición de control que ustedes definieron.

Elegir el estimando es parte del diseño

¿Cuál es el efecto de [tratamiento] frente a [condición de control]
sobre [resultado], medido en [momento],
en [población]?

En notación: $\mathbb{E}[Y_i(1) - Y_i(0)]$, donde $D_i = 1$ es el tratamiento y $D_i = 0$ es la condición de control que ustedes definieron.

Ejemplo vago: “¿Funciona la transparencia?”

Elegir el estimando es parte del diseño

¿Cuál es el efecto de [tratamiento] frente a [condición de control] sobre [resultado], medido en [momento], en [población]?

En notación: $\mathbb{E}[Y_i(1) - Y_i(0)]$, donde $D_i = 1$ es el tratamiento y $D_i = 0$ es la condición de control que ustedes definieron.

Ejemplo vago: “¿Funciona la transparencia?”

Ejemplo preciso: ¿Cuál es el efecto de repartir un volante con los resultados de la auditoría del gasto municipal (frente a no repartir nada) sobre la participación electoral, medida en la elección siguiente, entre los votantes registrados de municipios con auditorías publicadas?

El puente hacia el diseño

¿Qué estima realmente una diferencia de medias?

Lo único que podemos calcular con datos observados:

$$\mathbb{E}[Y_i \mid D_i = 1] - \mathbb{E}[Y_i \mid D_i = 0]$$

¿Qué estima realmente una diferencia de medias?

Lo único que podemos calcular con datos observados:

$$\mathbb{E}[Y_i \mid D_i = 1] - \mathbb{E}[Y_i \mid D_i = 0]$$

Sumando y restando $\mathbb{E}[Y_i(0) \mid D_i = 1]$, esto se descompone *exactamente* en:

¿Qué estima realmente una diferencia de medias?

Lo único que podemos calcular con datos observados:

$$\mathbb{E}[Y_i \mid D_i = 1] - \mathbb{E}[Y_i \mid D_i = 0]$$

Sumando y restando $\mathbb{E}[Y_i(0) \mid D_i = 1]$, esto se descompone *exactamente* en:

$$\underbrace{\mathbb{E}[Y_i(1) - Y_i(0) \mid D_i = 1]}_{\text{efecto causal (ATT)}} + \underbrace{\mathbb{E}[Y_i(0) \mid D_i = 1] - \mathbb{E}[Y_i(0) \mid D_i = 0]}_{\text{sesgo de selección}}$$

¿Qué estima realmente una diferencia de medias?

Lo único que podemos calcular con datos observados:

$$\mathbb{E}[Y_i \mid D_i = 1] - \mathbb{E}[Y_i \mid D_i = 0]$$

Sumando y restando $\mathbb{E}[Y_i(0) \mid D_i = 1]$, esto se descompone *exactamente* en:

$$\underbrace{\mathbb{E}[Y_i(1) - Y_i(0) \mid D_i = 1]}_{\text{efecto causal (ATT)}} + \underbrace{\mathbb{E}[Y_i(0) \mid D_i = 1] - \mathbb{E}[Y_i(0) \mid D_i = 0]}_{\text{sesgo de selección}}$$

El segundo término pregunta: ¿en qué se habrían diferenciado los dos grupos si nadie hubiera recibido el tratamiento?

Eso es exactamente lo que consigue la aleatorización

Independencia

$$\{Y_i(1), Y_i(0)\} \perp\!\!\!\perp D_i$$

Eso es exactamente lo que consigue la aleatorización

Independencia

$$\{Y_i(1), Y_i(0)\} \perp\!\!\!\perp D_i$$

- Si el tratamiento se asignó por sorteo, quién lo recibió **no tiene relación** con cuáles eran sus resultados potenciales.

Eso es exactamente lo que consigue la aleatorización

Independencia

$$\{Y_i(1), Y_i(0)\} \perp\!\!\!\perp D_i$$

- Si el tratamiento se asignó por sorteo, quién lo recibió **no tiene relación** con cuáles eran sus resultados potenciales.
- Entonces $\mathbb{E}[Y_i(0) \mid D_i = 1] = \mathbb{E}[Y_i(0) \mid D_i = 0]$ y el **sesgo de selección es cero**, por diseño.

Eso es exactamente lo que consigue la aleatorización

Independencia

$$\{Y_i(1), Y_i(0)\} \perp\!\!\!\perp D_i$$

- Si el tratamiento se asignó por sorteo, quién lo recibió **no tiene relación** con cuáles eran sus resultados potenciales.
- Entonces $\mathbb{E}[Y_i(0) \mid D_i = 1] = \mathbb{E}[Y_i(0) \mid D_i = 0]$ y el **sesgo de selección es cero**, por diseño.
- Y por la misma razón los tratados no son especiales en cuanto a su efecto:
 $\mathbb{E}[Y_i(1) - Y_i(0) \mid D_i = 1] = \mathbb{E}[Y_i(1) - Y_i(0)]$, es decir **ATT = ATE**. Hacen falta las dos cosas.

Eso es exactamente lo que consigue la aleatorización

Independencia

$$\{Y_i(1), Y_i(0)\} \perp\!\!\!\perp D_i$$

- Si el tratamiento se asignó por sorteo, quién lo recibió **no tiene relación** con cuáles eran sus resultados potenciales.
- Entonces $\mathbb{E}[Y_i(0) \mid D_i = 1] = \mathbb{E}[Y_i(0) \mid D_i = 0]$ y el **sesgo de selección es cero**, por diseño.
- Y por la misma razón los tratados no son especiales en cuanto a su efecto:
 $\mathbb{E}[Y_i(1) - Y_i(0) \mid D_i = 1] = \mathbb{E}[Y_i(1) - Y_i(0)]$, es decir **ATT = ATE**. Hacen falta las dos cosas.
- Recién ahí la diferencia de medias observada es un estimador **insesgado** del ATE.

Eso es exactamente lo que consigue la aleatorización

Independencia

$$\{Y_i(1), Y_i(0)\} \perp\!\!\!\perp D_i$$

- Si el tratamiento se asignó por sorteo, quién lo recibió **no tiene relación** con cuáles eran sus resultados potenciales.
- Entonces $\mathbb{E}[Y_i(0) \mid D_i = 1] = \mathbb{E}[Y_i(0) \mid D_i = 0]$ y el **sesgo de selección es cero**, por diseño.
- Y por la misma razón los tratados no son especiales en cuanto a su efecto:
 $\mathbb{E}[Y_i(1) - Y_i(0) \mid D_i = 1] = \mathbb{E}[Y_i(1) - Y_i(0)]$, es decir **ATT = ATE**. Hacen falta las dos cosas.
- Recién ahí la diferencia de medias observada es un estimador **insesgado** del ATE.

Y noten lo que *no* dice

La aleatorización no garantiza que los grupos sean idénticos **en esta muestra**. Garantiza que lo sean **en promedio, a lo largo de aleatorizaciones repetidas**. La diferencia entre esas dos cosas es la razón por la que existe la inferencia estadística.

La aleatorización no lo resuelve todo

Para leer la diferencia de medias como un efecto causal siguen haciendo falta dos supuestos:

- **SUTVA**: supuesto de valor estable del tratamiento por unidad.

No interferencia: el resultado potencial de una unidad depende de su propio tratamiento, no del tratamiento asignado a otras unidades. Puede fallar con difusión de información, contagios, redes sociales o mercados laborales locales.

Sin versiones ocultas: el tratamiento está suficientemente bien definido; no agrupamos bajo una misma etiqueta variantes que podrían producir efectos distintos.

La aleatorización no lo resuelve todo

Para leer la diferencia de medias como un efecto causal siguen haciendo falta dos supuestos:

- **SUTVA**: supuesto de valor estable del tratamiento por unidad.

No interferencia: el resultado potencial de una unidad depende de su propio tratamiento, no del tratamiento asignado a otras unidades. Puede fallar con difusión de información, contagios, redes sociales o mercados laborales locales.

Sin versiones ocultas: el tratamiento está suficientemente bien definido; no agrupamos bajo una misma etiqueta variantes que podrían producir efectos distintos.

- **Excluibilidad** (restricción de exclusión): la *asignación* afecta el resultado **solo a través del tratamiento**.

Este supuesto se rompe, por ejemplo, si el grupo de tratamiento recibe además más visitas del equipo, encuestas más largas o simplemente sabe que lo están observando.

Una advertencia práctica: variables postratamiento

Regla

Nunca controlen o condicionen por variables medidas **después** del tratamiento.

Una advertencia práctica: variables postratamiento

Regla

Nunca controlen o condicionen por variables medidas **después** del tratamiento.

- Ejemplo: un programa de capacitación laboral. Analizamos los salarios **solo entre quienes tienen empleo**.

Una advertencia práctica: variables postratamiento

Regla

Nunca controlen o condicionen por variables medidas **después** del tratamiento.

- Ejemplo: un programa de capacitación laboral. Analizamos los salarios **solo entre quienes tienen empleo**.
- Pero el programa **afecta quién tiene empleo**. Los dos grupos de “empleados” ya no son comparables.

Una advertencia práctica: variables postratamiento

Regla

Nunca controlen o condicionen por variables medidas **después** del tratamiento.

- Ejemplo: un programa de capacitación laboral. Analizamos los salarios **solo entre quienes tienen empleo**.
- Pero el programa **afecta quién tiene empleo**. Los dos grupos de “empleados” ya no son comparables.
- Si el programa emplea a personas que de otro modo no habrían trabajado (y que ganan poco), el programa **parecerá reducir los salarios**.

Una advertencia práctica: variables postratamiento

Regla

Nunca controlen o condicionen por variables medidas **después** del tratamiento.

- Ejemplo: un programa de capacitación laboral. Analizamos los salarios **solo entre quienes tienen empleo**.
- Pero el programa **afecta quién tiene empleo**. Los dos grupos de “empleados” ya no son comparables.
- Si el programa emplea a personas que de otro modo no habrían trabajado (y que ganan poco), el programa **parecerá reducir los salarios**.
- La aleatorización protege contra el sesgo de selección **en la asignación**, no contra el que ustedes introducen **en el análisis**.

Estudios observacionales: no son “malos”, son intensivos en supuestos

Estudio aleatorizado

- El investigador **asigna** el tratamiento.
- La independencia se obtiene **por diseño**.
- Alta **validez interna**.

Estudio observacional

- El tratamiento se **observa**, no se manipula.
- La independencia hay que **argumentarla**.
- Diferencias en diferencias, regresión discontinua, variables instrumentales, emparejamiento. . .

Estudios observacionales: no son “malos”, son intensivos en supuestos

Estudio aleatorizado

- El investigador **asigna** el tratamiento.
- La independencia se obtiene **por diseño**.
- Alta **validez interna**.

Estudio observacional

- El tratamiento se **observa**, no se manipula.
- La independencia hay que **argumentarla**.
- Diferencias en diferencias, regresión discontinua, variables instrumentales, emparejamiento. . .

La mayoría de las preguntas importantes **no** se pueden aleatorizar. El marco de resultados potenciales es igual de útil ahí: sirve para decir **exactamente qué habría que suponer** para que la comparación funcione.

- **Validez interna:** ¿el efecto que estimamos es realmente el efecto causal *en este estudio*? Esto es lo que garantiza (o facilita) la aleatorización.

Validez interna y validez externa

- **Validez interna:** ¿el efecto que estimamos es realmente el efecto causal *en este estudio*? Esto es lo que garantiza (o facilita) la aleatorización.
- **Validez externa:** ¿vale también en otro lugar, en otro momento, con otra población? Esto la aleatorización **no** lo garantiza.

Validez interna y validez externa

- **Validez interna:** ¿el efecto que estimamos es realmente el efecto causal *en este estudio*? Esto es lo que garantiza (o facilita) la aleatorización.
- **Validez externa:** ¿vale también en otro lugar, en otro momento, con otra población? Esto la aleatorización **no** lo garantiza.
- Es una preocupación general de toda la ciencia social, no un defecto de los experimentos.

Validez interna y validez externa

- **Validez interna:** ¿el efecto que estimamos es realmente el efecto causal *en este estudio*? Esto es lo que garantiza (o facilita) la aleatorización.
- **Validez externa:** ¿vale también en otro lugar, en otro momento, con otra población? Esto la aleatorización **no** lo garantiza.
- Es una preocupación general de toda la ciencia social, no un defecto de los experimentos.

Cómo se acumula conocimiento

La iniciativa **Metaketa** de EGAP coordina *ex ante* varios estudios en distintos países con diseños armonizados, para poder combinarlos después en un metaanálisis. (Dunning et al. 2019)

Validez interna y validez externa

- **Validez interna:** ¿el efecto que estimamos es realmente el efecto causal *en este estudio*? Esto es lo que garantiza (o facilita) la aleatorización.
- **Validez externa:** ¿vale también en otro lugar, en otro momento, con otra población? Esto la aleatorización **no** lo garantiza.
- Es una preocupación general de toda la ciencia social, no un defecto de los experimentos.

Cómo se acumula conocimiento

La iniciativa **Metaketa** de EGAP coordina *ex ante* varios estudios en distintos países con diseños armonizados, para poder combinarlos después en un metaanálisis. (Dunning et al. 2019)

La respuesta a la validez externa no es un estudio más grande: es una **agenda** de estudios.

En conclusión

1. Un efecto causal es **una resta entre dos mundos**, uno de los cuales nunca observamos.

En conclusión

1. Un efecto causal es **una resta entre dos mundos**, uno de los cuales nunca observamos.
2. El problema fundamental hace que τ_i sea inalcanzable; por eso trabajamos con **promedios**, y por eso hay que elegir *cuál*.

En conclusión

1. Un efecto causal es **una resta entre dos mundos**, uno de los cuales nunca observamos.
2. El problema fundamental hace que τ_i sea inalcanzable; por eso trabajamos con **promedios**, y por eso hay que elegir *cuál*.
3. Antes de pensar en datos o en métodos: escriban su **estimando**. Tratamiento, control, resultado, momento, población.

En conclusión

1. Un efecto causal es **una resta entre dos mundos**, uno de los cuales nunca observamos.
2. El problema fundamental hace que τ_i sea inalcanzable; por eso trabajamos con **promedios**, y por eso hay que elegir *cuál*.
3. Antes de pensar en datos o en métodos: escriban su **estimando**. Tratamiento, control, resultado, momento, población.
4. La diferencia de medias = **efecto** + **sesgo de selección**. Todo diseño es un argumento sobre el segundo término.

En conclusión

1. Un efecto causal es **una resta entre dos mundos**, uno de los cuales nunca observamos.
2. El problema fundamental hace que τ_i sea inalcanzable; por eso trabajamos con **promedios**, y por eso hay que elegir *cuál*.
3. Antes de pensar en datos o en métodos: escriban su **estimando**. Tratamiento, control, resultado, momento, población.
4. La diferencia de medias = **efecto** + **sesgo de selección**. Todo diseño es un argumento sobre el segundo término.
5. La aleatorización lo anula por construcción — pero no les regala SUTVA, ni excluibilidad, ni validez externa.

Checklist para hacer una pregunta causal

Elemento	La pregunta
Unidad	¿A quién o a qué se le asigna el tratamiento?
Población	¿A qué universo aplica la respuesta?
Tratamiento	¿Qué se manipula, exactamente?
Control	¿Contra qué se compara?
Resultado	¿Qué se mide, y cuándo?
Aleatorización	¿Cómo se asigna, y con qué probabilidad?
Ética	¿Qué riesgos crea intervenir o medir?
Amenazas	¿Qué supuesto es el más frágil <i>aquí</i> ?

Referencias

- Angrist, J. y J.-S. Pischke. 2009. *Mostly Harmless Econometrics*. Princeton University Press.
- Brady, H. 2008. "Causation and Explanation in Social Science". En *The Oxford Handbook of Political Methodology*.
- Cartwright, N. y J. Hardie. 2012. *Evidence-Based Policy: A Practical Guide to Doing It Better*. Oxford University Press.
- Dunning, T., G. Grossman, M. Humphreys, S. Hyde, C. McIntosh y G. Nellis (eds.). 2019. *Information, Accountability, and Cumulative Learning: Lessons from Metaketa I*. Cambridge University Press.
- Gerber, A. y D. Green. 2012. *Field Experiments: Design, Analysis, and Interpretation*. Norton.
- Hernán, M. 2016. "Does Water Kill? A Call for Less Casual Causal Inferences". *Annals of Epidemiology* 26(10): 674–680.
- Holland, P. 1986. "Statistics and Causal Inference". *Journal of the American Statistical Association* 81(396): 945–960.
- Imbens, G. y D. Rubin. 2015. *Causal Inference for Statistics, Social, and Biomedical Sciences*. Cambridge University Press.
- Manski, C. 1995. *Identification Problems in the Social Sciences*. Harvard University Press.
- Messerli, F. 2012. "Chocolate Consumption, Cognitive Function, and Nobel Laureates". *New England Journal of Medicine* 367(16): 1562–1564.
- Mize, T. y B. Manago. 2022. "The Past, Present, and Future of Experimental Methods in the Social Sciences". *Social Science Research* 108: 102799.
- Montgomery, J., B. Nyhan y M. Torres. 2018. "How Conditioning on Posttreatment Variables Can Ruin Your Experiment and What to Do About It". *American Journal of Political Science* 62(3): 760–775.
- Torreblanca, C., W. Dinneen, G. Grossman y Y. Xu. 2026. "The Credibility Revolution in Political Science". Manuscrito de trabajo, SocArXiv. doi:10.31235/osf.io/w2kmc
- Rubin, D. 1974. "Estimating Causal Effects of Treatments in Randomized and Nonrandomized Studies". *Journal of Educational Psychology* 66(5): 688–701.

¡Gracias!

Omar García-Ponce

www.omargarciaponce.com

garciaponce@gwu.edu