

Amenazas a la validez de experimentos aleatorizados

Elegir bien T y Y ahora para evitar amenazas después

Santiago López-Cariboni
EGAP Learning Days — Santiago de Chile

Día 1 — julio 2026

Objetivos de la sesión

Parte 1 — Fijar un tratamiento aleatorizable (T)

Parte 2 — Cómo y a qué nivel medir Y

Parte 3 — Elegirlos juntos

Validez interna y externa

Taller

Objetivos de la sesión

¿Qué necesitamos *fijar*?

- ▶ **Un tratamiento T que se pueda aleatorizar:** qué es, a qué nivel se asigna, con cuántos brazos y cómo se entrega.
- ▶ **Una variable de resultado Y :** qué mide, a qué nivel, con qué fuente y en qué momento.

La idea central

Elegir bien T y Y **ahora** es la forma más barata de evitar las amenazas a la validez interna **después**. Casi ningún problema del análisis se arregla con estadística; casi todos se arreglan en el diseño.

Las amenazas nacen en T y en Y

Las amenazas clásicas a la validez interna no son accidentes: se incuban en cómo definimos el tratamiento y cómo medimos el resultado.

Decisión de diseño	Amenaza que puede provocar
Cómo definimos y entregamos T	Incumplimiento, derrame (interferencia), entrega diferencial entre brazos
Cómo y a qué nivel medimos Y	Deserción, efecto Hawthorne, medición diferencial entre brazos

Hoy tomamos esas decisiones **mirando hacia adelante**: elegimos T y Y para que esas amenazas no aparezcan.

Notación mínima (de la sesión de inferencia causal)

- ▶ Z : **asignación aleatoria** (lo que el diseño sortea).
- ▶ D : **recepción del tratamiento** (lo que la unidad efectivamente recibe).
- ▶ Y : **variable de resultado**.

Con cumplimiento perfecto, $Z = D$ y simplemente lo llamamos T .

Recordamos el efecto individual como comparación de resultados potenciales,

$$\tau_i = Y_i(T_i = 1) - Y_i(T_i = 0),$$

y el efecto promedio del tratamiento $\bar{\tau} = \frac{1}{n} \sum_{i=1}^n \tau_i$.

Parte 1 — Fijar un tratamiento aleatorizable (T)

No hay causalidad sin manipulación

Holland (1986)

Solo podemos estimar el efecto causal de aquello que **podemos manipular** (asignar a unas unidades y no a otras).

- ▶ “Ser mujer”, “ser pobre”, “ser de izquierda” **no son tratamientos**: no podemos asignarlos al azar.
- ▶ Un tratamiento es una **intervención concreta**: un mensaje, un taller, una transferencia, un trámite, una visita.
- ▶ **Prueba rápida**: ¿puedo escribir el procedimiento por el cual una unidad *recibe* *T* y otra *no*? Si no puedo, todavía no tengo un tratamiento.

De un concepto difuso a una intervención concreta

Su teoría habla de un concepto; su experimento necesita una **acción**.

Concepto (teoría)	Intervención aleatorizable (T)
"Más información"	Un SMS con el dato de asistencia del hijo
"Más confianza en el Estado"	Una carta firmada por la autoridad local
"Menos fricción"	Un formulario pre-llenado
"Rendición de cuentas"	Publicar la clasificación de la dependencia

Aísla el ingrediente activo

Si el "tratamiento" cambia cinco cosas a la vez, no sabrá cuál causó el efecto. Cambie **una** cosa entre brazos; mantenga todo lo demás igual.

¿A qué nivel aleatorizar?

El tratamiento se asigna a **unidades**, y usted elige cuál es la unidad.

- ▶ **Individuo** (persona, hogar): máxima potencia estadística.
- ▶ **Conglomerado (cluster)**: escuela, aula, barrio, clínica, municipio.

Elija el nivel según:

1. **Dónde se puede intervenir** (logística y política): a veces solo se puede tratar la escuela entera, no al alumno.
2. **Ética**: qué es aceptable ofrecer o retener, y a quién.
3. **Derrame**: si el efecto “se contagia” entre vecinos, aleatorizar al individuo contamina el control.

Regla práctica

Aleatorice al nivel más bajo que sea *factible* y que *contenga* el derrame dentro del conglomerado.

Brazos: empeece binario y manténgalos simétricos

- ▶ **Binario**: tratamiento vs. control. Simple y potente; empeece aquí.
- ▶ **Multi-brazo**: varias versiones del tratamiento (p. ej. mensaje cívico vs. mensaje de costo) para comparar *mecanismos*, no solo “¿funciona?”.
- ▶ **Dosis / intensidad**: misma intervención en distinta cantidad (una visita vs. tres).


Simetría entre brazos

Todos los brazos deben ser **idénticos excepto por el tratamiento en sí**: mismo contacto, mismo formato, mismo encuestador, mismo momento. Toda diferencia adicional es un tratamiento escondido.

Defina también el control: puro (nada), activo (lo de siempre) o lista de espera (recibe después — suele resolver la objeción ética). El contraste que estima depende de esta elección: “ T vs. nada” $\neq$ “ T vs. el programa actual”.

Cuando no puede obligar: diseños de estímulo

A veces no puede *imponer* el tratamiento, solo *ofrecerlo*. Entonces aleatoriza el **estímulo (encouragement)**, no la recepción.



- ▶ Usted aleatoriza Z ; la persona decide si toma el tratamiento (D).
- ▶ **La asignación solo debe afectar Y a través de D** (restricción de exclusión).
- ▶ El efecto de *ser asignado* (ITT) no es el de *recibir* el tratamiento: el LATE/CACE es el efecto solo en los *cumplidores*.
- ▶ Del ITT al LATE hace falta más que la exclusión (relevancia y monotonicidad); lo vemos en estimación.

Qué amenazas evita una buena elección de T

Al fijar T hoy, ya está previniendo:

- ▶ **Incumplimiento:** si el tratamiento es fácil de recibir y de verificar, $Z \approx D$. Un estímulo creíble y de bajo costo sube el cumplimiento.
- ▶ **Derrame / interferencia:** aleatorizar al nivel de conglomerado y separar unidades tratadas de las de control contiene el “contagio”.
- ▶ **Entrega diferencial:** brazos simétricos evitan que el grupo de tratamiento reciba, sin querer, atención extra.

Ninguna de estas se arregla después con un modelo. Se arreglan eligiendo bien la unidad, el estímulo y la simetría.

Parte 2 — Cómo y a qué nivel medir Y

Del concepto a la medida

Y es lo que su teoría dice que T debería **mover**. Empiece por ahí.

- ▶ ¿Cuál es el resultado que, si el tratamiento funciona, debería cambiar?
- ▶ ¿Existe una medida creíble de ese resultado? ¿La puede recoger para *todas* las unidades?
- ▶ ¿La medida es sensible al efecto esperado, o es tan ruidosa que nunca detectará el cambio?

Ancle Y en la teoría

Si no puede explicar por qué T debería mover *esta* Y , todavía no tiene un resultado — tiene una variable disponible.

El nivel de Y debe coincidir con el nivel de T

Mida Y **al mismo nivel** al que aleatorizó (o a un nivel que se pueda agregar hasta ahí).

- ▶ Aleatorizó **escuelas** $\Rightarrow$ puede medir resultados de la escuela, o de alumnos y **agregar** a la escuela.
- ▶ Aleatorizó **individuos** $\Rightarrow$ mida al individuo.

El desajuste típico

Aleatoriza el municipio pero mide una sola encuesta municipal: termina con N efectivo = número de municipios, no de personas. Su potencia estadística vive en el nivel de aleatorización, no en el de la encuesta.

¿De dónde salen los datos de Y?

Fuente	Ventaja	Riesgo
Encuesta (autorreporte)	Flexible, mide actitudes	Deserción, reactividad, sesgo de deseabilidad
Administrativa (registros)	Completa, barata, objetiva	Acceso, calidad, desfase temporal
Conductual / observada	Difícil de manipular	Costosa, a veces intrusiva

Cuando pueda, prefiera **datos que existan para todas las unidades sin depender de que respondan** (registros administrativos): es la mejor defensa contra la deserción.

¿En qué momento medir?

- ▶ **Línea de base (baseline):** antes del tratamiento. Sirve para verificar balance y para ganar precisión, no para “arreglar” desbalances.
- ▶ **Medición final (endline):** después, con el tiempo suficiente para que el efecto aparezca.
- ▶ **Mida al mismo tiempo y de la misma manera en todos los brazos.**

El reloj también es diseño

Medir demasiado pronto: el efecto aún no ocurrió. Demasiado tarde: se diluyó o la gente se mudó. Elija el momento a partir de su teoría del cambio.

Qué amenazas evita una buena medición de Y

- ▶ **Deserción** (datos faltantes en Y): peligrosa cuando la provoca el tratamiento. La combaten los datos administrativos, la planificación del rastreo y el presupuesto para el seguimiento.
- ▶ **Efecto Hawthorne / reactividad**: saberse observado cambia la conducta. La combate una medición **discreta** e idéntica en todos los brazos.
- ▶ **Medición diferencial**: nunca mida al grupo de tratamiento “un poco más” o con otro instrumento. Mismo cuestionario, mismos encuestadores, mismo momento.

Buenas prácticas: mida discreto, ciego e igual en todos los brazos

- ▶ Recoja los datos de la forma más **discreta** posible.
- ▶ En lo posible, **nadie más que la propia unidad** conoce su condición; los encuestadores están **ciegos** a la asignación.
- ▶ **No** haga mediciones adicionales solo para el grupo de tratamiento.
- ▶ Planifique cómo **encontrará** a las unidades para la medición final (contactos, consentimiento, incentivos de respuesta iguales en todos los brazos).

Parte 3 — Elegirlos juntos

T y Y se eligen *juntos*

No son dos decisiones separadas: deben **encajar entre sí y con la teoría**.

- ▶ El **nivel** de Y sigue al nivel de T .
- ▶ El **momento** de Y sigue a cuándo actúa T .
- ▶ La **fuerza** de Y debe cubrir a todas las unidades que T toca (y a las que podría “derramar”).
- ▶ Un brazo bien definido no sirve de nada si Y no es sensible a él.

Pregunta guía

"Si mi tratamiento funciona exactamente como mi teoría predice, ¿qué número cambia, en quién, y cuándo?" Esa frase contiene su T , su Y , su nivel y su momento.

Ejemplo 1 — Nivel individual: SMS al contribuyente

Tratamiento T — impuesto predial municipal

Un SMS para promover el pago a tiempo. Brazos: (A) recordatorio disuasivo, (B) apelación cívica, (C) control. Mismo remitente, hora y extensión; **solo cambia el texto**.

Nivel: individual (cuenta). El pago de una cuenta no suele afectar el de otra (derrame mínimo), la entrega es individual y gana potencia.

Aleatoriza Z = enviar; registra D = entrega/lectura. El ITT (efecto de *mandar* el SMS) suele ser la pregunta de la administración.

Resultado Y

Pagó a tiempo (0/1) y monto, a **nivel de cuenta** (= nivel de T). Fuente: **registros de tesorería** (sin deserción ni reactividad: no saben que están en un estudio). Momento: base = ciclo anterior; final = misma fecha de corte en todos los brazos.

Desactiva: deserción (nula), Hawthorne (mínima), incumplimiento (el ITT sigue válido; D se registra para el LATE), derrame (asumido mínimo entre cuentas).

Ejemplo 2 — Nivel conglomerado: lectura en escuelas

Tratamiento T — programa de lectura remedial

Currículo estructurado + 6 semanas de sesiones diarias con docentes capacitados.

Nivel: escuela (conglomerado). Contiene el derrame (los niños se copian y juegan juntos), la entrega es a la clase entera y es más aceptable (con **lista de espera**: el control lo recibe al año siguiente). Costo: la potencia la manda el número de **escuelas** (conglomerados); sumar niños por escuela ayuda, pero con rendimientos decrecientes.

Resultado Y

Fluidez y comprensión en una prueba oral estandarizada. Medida al **niño** pero **agregable a la escuela** (= nivel de T). Fuente: **conductual** (una prueba), con evaluadores **ciegos** a la condición y el mismo instrumento. Momento: base al inicio, final tras el programa, misma ventana.

Desactiva: derrame (contenido), medición diferencial (evaluadores ciegos), deserción (rastreo por matrícula), reactividad (prueba de destreza).

Alertas (I): errores al fijar el tratamiento T

En el tratamiento T

- ▶ Elegir un T que no se puede asignar (género, pobreza, ideología): son *atributos* preexistentes (covariables o moderadores), no tratamientos.
- ▶ Un T que es un constructo ("concientización") sin manual de entrega.
- ▶ Brazos que difieren en *más* que el ingrediente activo $\Rightarrow$ mide atención, no tratamiento.
- ▶ Aleatorizar a nivel individual cuando hay derrame obvio, o a un nivel demasiado alto sin necesidad (pocos conglomerados, poca potencia).
- ▶ Comparar por D (los que tomaron) en vez de por Z (los asignados) $\Rightarrow$ tira la aleatorización a la basura. Y no registrar $D \Rightarrow$ luego no hay LATE.

Alertas (II): errores al fijar el resultado Y

En el resultado Y

- ▶ Medir Y a un nivel que **no se agrega** al nivel de T ; contar personas cuando su N real son los conglomerados.
- ▶ Usar autorreporte reactivo cuando existe una medida administrativa o conductual válida.
- ▶ No tener línea de base, o medirla distinto entre brazos.
- ▶ Medición final demasiado temprana (el efecto no llegó) o demasiado tardía (ya se diluyó).
- ▶ Esforzarse más por encontrar al grupo tratado que al control $\Rightarrow$ deserción diferencial.
- ▶ Medir 20 resultados "a ver cuál da" $\Rightarrow$ falsos positivos programados.

Lista de verificación: qué dejar fijado hoy

Tratamiento T

- ☐ Es una intervención concreta y asignable
- ☐ Nivel de aleatorización
- ☐ Número de brazos y dosis
- ☐ Cómo se entrega y se verifica
- ☐ Brazos simétricos

Resultado Y

- ☐ Anclado en la teoría
- ☐ Nivel = nivel de T
- ☐ Fuente (encuesta / administrativa / conductual)
- ☐ Momento (base / final)
- ☐ Mismo instrumento en todos los brazos
- ☐ Plan contra la deserción

Validez interna y externa

Fortalezas y limitaciones

Fortaleza:

- ▶ Validez interna


Limitaciones:

- ▶ Desgaste
- ▶ Efecto derrame
- ▶ Ética
- ▶ Validez externa

Validez interna y externa

Validez externa: la *muestra* de la evaluación representa con precisión a la población de unidades elegibles.

Validez interna: El impacto estimado del programa es el impacto libre de todos los demás factores de confusión potenciales (o, en otras palabras, que el grupo de comparación represente una estimación precisa del contrafactual de modo que se estime el verdadero impacto del programa).




Fuente: Gertler, et al. (2017).

Validez interna y externa

1. Definir las unidades elegibles

2. Seleccionar la muestra de evaluación

3. Asignar aleatoriamente al tratamiento



Fuente: Gertler, et al. (2017).


Respuestas a la “crisis” de validez externa

- ▶ Investigar la existencia de efectos de tratamiento heterogéneos
 - ▶ Interacción entre T_i y características de los sujetos X_i (sexo, edad, educación, lugar de residencia, etc.)
 - ▶ Depende de observables en X .

Respuestas a la “crisis” de validez externa

- ▶ Investigar la existencia de efectos de tratamiento heterogéneos
 - ▶ Interacción entre T_i y características de los sujetos X_i (sexo, edad, educación, lugar de residencia, etc.)
 - ▶ Depende de observables en X .
- ▶ Replicación

Metaketa Initiative



Metaketa Initiative Project Locations

The **Metaketa Initiative** is a collaborative research model aimed at improving the accumulation of knowledge from field experiments on topics where academic researchers and policy practitioners share substantive interests. EGAP funds and coordinates studies across countries, clustered by theme, to improve and incentivize innovative research alongside integrated analysis and publication.

Context: EGAP sees an **on-going crisis of external validity** of development research and few systemic efforts to address it. The business-as-usual model for many academic researchers is to select topics they find interesting and seek funding to implement the research in an original way. In practice, this often means the **results may be difficult to integrate** with learning developed in **other contexts**. Other research is done in the context of policy evaluation. In these cases, the research is sometimes commissioned by development agencies and implemented by researchers. Often this research responds strongly to particular local needs but is not designed to answer questions that span variegated contexts. A consequence of this is that **major policy innovations often rest on fragile research foundations**.

For example, major lessons have been drawn on the effectiveness of community-based monitoring of health workers for health gains, or on the advantages of disseminating information on corruption about politicians—all from single studies. Yet there are well known reasons for caution, not least because of the presence of publication bias affecting academic research. Positive results get published and read, negative or null results often disappear, and little is learned about the role that context plays in determining when a finding is relevant or not.

Solution: EGAP is trying to change this challenge of external validity, in part by **getting the incentives right** to attract the best researchers to contribute to a collective endeavor that **identifies critical areas** where **generalizable knowledge** can have a **large impact**. The key idea of this initiative is to take a major question of policy importance for governance outcomes, identify an intervention that is tried, but not tested, and implement a cluster of coordinated research studies that can provide a reliable answer to the question.

Metaketa Rounds

- I. Information and Accountability
- II. Taxation
- III. Natural Resource Governance
- IV. Community Policing
- V. Women's Action Committees and Local Services

Recent Press Publications

Eight Principles of the Metaketa Initiative

- Coordination across research teams
- Predefined themes and comparable interventions
- Comparable measures
- Integrated case selection
- Preregistration
- Third-party analysis
- Formal synthesis
- Integrated publication


SITE SELECTION BIAS IN PROGRAM EVALUATION*

HUNT ALLCOTT

“Site selection bias” can occur when the probability that a program is adopted or evaluated is correlated with its impacts. I test for site selection bias in the context of the Opower energy conservation programs, using 111 randomized control trials involving 8.6 million households across the United States. Predictions based on rich microdata from the first 10 replications substantially overstate efficacy in the next 101 sites. Several mechanisms caused this positive selection. For example, utilities in more environmentalist areas are more likely to adopt the program, and their customers are more responsive to the treatment. Also, because utilities initially target treatment at higher-usage consumer subpopulations, efficacy drops as the program is later expanded. The results illustrate how program evaluations can still give systematically biased out-of-sample predictions, even after many replications. *JEL* Codes: C93, D12, L94, O12, Q41.

Allcott, H. (2015). Site Selection Bias in Program Evaluation. *The Quarterly Journal of Economics*, 130(3), 1117–1165. <https://doi.org/10.1093/qje/qjv015>

Replicación y sesgos de selección



Allcott, H. (2015). Site Selection Bias in Program Evaluation. *The Quarterly Journal of Economics*, 130(3), 1117–1165. <https://doi.org/10.1093/qje/qjv015>

Para profundizar

- ▶ **Holland (1986)** — “no causation without manipulation”: por qué género o pobreza no son tratamientos.
- ▶ **Gerber & Green (2012)**, *Field Experiments* — texto base: nivel de aleatorización, cumplimiento, ITT, deserción, medición.
- ▶ **Duflo, Glennerster & Kremer (2007)** — guía práctica: diseños de estímulo, conglomerados y potencia.
- ▶ **Angrist, Imbens & Rubin (1996)** — Z vs. D , cumplidores, ITT y LATE (para la sesión de estimación).
- ▶ **Gertler et al. (2017)**, *La evaluación de impacto en la práctica* — validez interna vs. externa.
- ▶ **Allcott (2015)**, *QJE* — sesgo de selección de sitios: por qué replicar no basta para la validez externa.

Taller

Su turno

Para su proyecto, escriba una frase:

"Si mi tratamiento _____ funciona, entonces
_____ (mi Y), medido en _____ (nivel), con
_____ (fuente), _____ (cuándo), debería cambiar."

Luego responda:

1. ¿A qué nivel puede aleatorizar T ? ¿Por qué ese nivel?
2. ¿Su Y existe para *todas* las unidades? Si no, ¿cómo evitará la deserción?
3. ¿Qué amenaza le preocupa más, y qué decisión de diseño la contiene?

¿Preguntas?

Lo llevamos al taller y a la ficha de diseño (Design form).