

Estimando estimandos con estimadores

Jake Bowers — EGAP Learning Days, Santiago de Chile

2026-07-30

Tabla de contenidos I

- 1 Puntos clave
- 2 Recapitulación
- 3 Estimandos, estimadores y promedios
- 4 Aleatorización en bloques
- 5 Aleatorización por conglomerados
- 6 Variables de resultado binarias
- 7 Ajuste de covarianza
- 8 Conclusión
- 9 Efectos causales que varían por grupos o por covariables
- 10 Efectos causales cuando no controlamos la dosis

Sección 1

Puntos clave

Puntos clave para la estimación I

- Un efecto causal, τ_i , es una comparación de resultados potenciales no observados para cada unidad i , por ejemplo: $\tau_i = Y_i(T_i = 1) - Y_i(T_i = 0)$ o $\tau_i = \frac{Y_i(T_i=1)}{Y_i(T_i=0)}$.
- Para aprender sobre τ_i , podemos tratar a τ_i como un **estimando** o una cantidad objetivo a ser estimada (discutido acá), o como una cantidad objetivo sobre la cual se plantearán hipótesis (sesión de pruebas de hipótesis).
- Hay muchas personas que se enfocan en el **estimando** del **efecto promedio del tratamiento** (average treatment effect, ATE), $\bar{\tau} = \frac{1}{n} \sum_{i=1}^n \tau_i$, en parte, porque permite una **estimación** fácil.

Puntos clave para la estimación II

La clave para la estimación en la inferencia causal es elegir un estimando que permita aprender sobre alguna pregunta teórica o de políticas públicas. Para esto, el ATE es una opción, pero otros estimandos comunes también incluyen el ITT, LATE/CACE, ATT o ATE para algún subgrupo (o incluso una diferencia de un efecto causal entre grupos).

- Un **estimador** es una fórmula para hacer una estimación (o cálculo de un número o intervalo) sobre el valor de un estimando. Por ejemplo, la diferencia de medias observadas para m unidades tratadas es un estimador de $\bar{\tau}$: $\hat{\tau} = \frac{\sum_{i=1}^n (T_i Y_i)}{m} - \frac{\sum_{i=1}^n ((1-T_i) Y_i)}{(n-m)}$.

Esto es algo que podemos calcular con datos observados. Llamamos a un cálculo una “estimación” porque tenemos la esperanza de que este cálculo con cantidades observadas nos diga algo sobre un no observable como: $\bar{\tau} = \bar{Y}_i(1) - \bar{Y}_i(0)$.

Puntos clave para la estimación III (Pruebas e intervalos de confianza)

- El **error estándar** de un estimador en un experimento aleatorio resume cómo variarían las estimaciones si se repitiera el experimento. (No se refiere comúnmente a la variabilidad de muestras de una población)
- Usamos el **error estándar** para producir **intervalos de confianza** y **valores p** para que podamos comenzar con un estimador y terminemos con una prueba de hipótesis.
- Diferentes aleatorizaciones producirán diferentes valores del mismo estimador que busca estimar el mismo estimando. Un **error estándar** resume esta variabilidad en un estimador.
- Un **intervalo de confianza** del $100(1 - \alpha) \%$ es una colección de hipótesis que no se pueden rechazar a un nivel α . Es común reportar intervalos de confianza que contienen hipótesis sobre los valores de nuestro estimando y usar nuestro estimador como una estadística de prueba.

Puntos clave sobre la estimación IV

- Los estimadores deberían tener una relación conocida con “la verdad” (el estimando):
 - evitar errores sistemáticos al estimar el estimando (ser insesgados);
 - variar poco en las estimaciones de un experimento a otro. (ser precisos o eficientes) y
 - quizá idealmente converger al estimando a medida que se utiliza más información (ser consistentes).

Estar “cerca” del estimando (preciso y con poco o ningún sesgo)

Puntos clave sobre la estimación V

- **Analizar conforme se aleatoriza** en cuanto a la estimación significa que (1) nuestros errores estándar deben medir la variabilidad de la aleatorización y (2) el objetivo de nuestros estimadores debe ser estimandos definidos en términos de resultados potenciales.
- No decimos que usamos **variables de control** cuando analizamos datos provenientes de experimentos aleatorios aunque sí usamos **ajuste de covarianza** (que son cálculos idénticos). Las covariables pueden hacer que nuestra estimación sea más **precisa**. Tengan en cuenta que es diferente controlar en estudios observacionales a hacer **ajuste de covarianza** en experimentos aleatorios aunque, algunos se usa el mismo comando de `lm(Y~Z+x)` en R.
- Ajuste de covarianza simple produce un estimador sesgado (**Lin 2013**). Pero el sesgo se hace pequeño en cuanto el N se hace grande.

Sección 2

Recapitulación

Recapitulación: Efectos causales

Recapitulación: La inferencia causal se puede resumir en una comparación de resultados potenciales fijos no observados.

Por ejemplo:

- el resultado potencial, o posible, de la unidad i cuando se asigna al tratamiento, $T_i = 1$ es $Y_i(T_i = 1)$.
- el resultado potencial, o posible, de la unidad i cuando se asigna al control, $T_i = 0$ es $Y_i(T_i = 0)$

La asignación al tratamiento, T_i , tiene un efecto causal para la unidad i al que llamamos τ_i , si $Y_i(T_i = 1) - Y_i(T_i = 0) \neq 0$ o $Y_i(T_i = 1) \neq Y_i(T_i = 0)$.

Sección 3

Estimandos, estimadores y promedios

¿Cómo podemos aprender sobre los efectos causales utilizando los datos observados?

- 1 Recordemos que podemos **probar hipótesis** sobre los dos resultados potenciales $\{Y_i(T_i = 1), Y_i(T_i = 0)\}$.
- 2 Podemos **definir estimandos** en términos de $\{Y_i(T_i = 1), Y_i(T_i = 0)\}$ o τ_i , **desarrollar estimadores** para esos estimandos, y luego calcular los valores y los errores estándar para esos estimadores.

Un estimando y un estimador común: el efecto promedio del tratamiento y la diferencia de medias

Supongamos que estamos interesados en el ATE, o $\bar{\tau} = \frac{1}{n} \sum_{i=1}^n \tau_i$. ¿Cuál sería un buen estimador?

Dos candidatos:

- 1 La diferencia de medias: $\hat{\bar{\tau}} = \frac{\sum_{i=1}^n (T_i Y_i)}{m} - \frac{\sum_{i=1}^n ((1-T_i) Y_i)}{n-m}$.
- 2 Una diferencia de medias después de recodificar el valor máximo de las observaciones Y_i (una especie de media “truncada” (winsorized), con lo que se busca evitar que los valores extremos ejerzan demasiada influencia sobre nuestro estimador; se usa para aumentar la *precisión*).

¿Cómo saber cuál estimador es mejor para un diseño de investigación en particular?

¡Simulemos!

Paso 1 de la simulación: generar datos con un ATE conocido

Tengan en cuenta que necesitamos *conocer* los resultados potenciales y la asignación al tratamiento para saber si el estimador propuesto funciona bien.

Z	y0	y1
0	0	10
0	0	30
0	0	200
0	1	91
1	1	11
1	3	23
0	4	34
0	5	45
1	190	280
1	200	220

El ATE real es 54

En la vida real sólo podemos observar una realización de los resultados potenciales. Recuerden que cada unidad tiene su propio efecto bajo el tratamiento.

Primero: generar datos artificiales

La tabla de la diapositiva anterior fue generada en R con:

```
# Tenemos 10 unidades
N <- 10
# y0 es el resultado potencial bajo el control
y0 <- c(0, 0, 0, 1, 1, 3, 4, 5, 190, 1000)
# Para cada unidad el efecto del tratamiento es intrínseco
tau <- c(10, 30, 200, 90, 10, 20, 30, 40, 90, 20)
## y1 es el resultado potencial bajo el tratamiento
y1 <- y0 + tau
# Dos bloques: a y b
block <- c("a", "a", "a", "a", "a", "a", "b", "b", "b", "b")
# Z es la asignación al tratamiento
# (en el código usamos Z en vez de T)
Z <- c(0, 0, 0, 0, 1, 1, 0, 0, 1, 1)
# Y es el resultado observado
Y <- Z * y1 + (1 - Z) * y0
# Los datos
dat <- data.frame(Z = Z, y0 = y0, y1 = y1, tau = tau, b = block, Y = Y, id = seq_len(N))
set.seed(12345)
```

DeclareDesign

En DeclareDesign se pueden representar diseños de investigación en unos pocos pasos:

```
# # Seleccionar los resultados potenciales bajo control y tratamiento
small_dat <- dat[, c("y0", "y1", "id")]

# El primer paso en DeclareDesign es declarar la población
pop <- declare_population(small_dat)
N <- nrow(pop)

# 2 unidades asignadas al tratamiento; DD hace asignación completa con m=2
trt_assign <- declare_assignment(Z = conduct_ra(N = N, m = 2))
# El valor observado de Y es y1 si Z=1 y y0 si Z=0
pot_out <- declare_potential_outcomes(Y ~ Z * y1 + (1 - Z) * y0)

# Especificar variable de resultado y asignación al tratamiento
reveal <- declare_reveal(Y, Z)

# El objeto de diseño de investigación básico
# incluye cuatro objetos
base_design <- pop + trt_assign + pot_out + reveal
```


DeclareDesign: creación de datos artificiales

DeclareDesign renombra y0 y y1 como Y_Z_0 y Y_Z_1 por defecto:

```
## Una simulación es una asignación aleatoria al tratamiento
sim_dat1 <- draw_data(base_design)

# Datos simulados (sólo las primeras 6 líneas)
head(sim_dat1)
```

	y0	y1	id	Z	Y_Z_0	Y_Z_1	Y
1	0	10	1	0	0	10	0
2	0	30	2	1	0	30	30
3	0	200	3	0	0	200	0
4	1	91	4	0	1	91	1
5	1	11	5	0	1	11	1
6	3	23	6	1	3	23	23

Utilizando DeclareDesign: definiendo estimandos y estimadores

El siguiente código no produce ningún resultado. Sólo define las funciones, los estimadores y un estimando.

```
## El estimando
estimandATE <- declare_inquiry(ATE = mean(Y_Z_1 - Y_Z_0))

## El primer estimador es la diferencia de medias
diff_means <- declare_estimator(Y ~ Z,
  inquiry = estimandATE,
  .method = lm_robust, se_type = "classical", label = "Diff-Means/OLS"
)
```

DeclareDesign: definiendo estimandos y estimadores

```
## El segundo estimador es la diferencia de medias recodificada (truncada)

## Primero hagamos una función para recodificar el valor máximo (top-coding)
topcode_var <- function(x) {
  rank_x <- rank(x)
  ## Reemplazamos el valor máximo de Y por el segundo valor más alto de Y
  new_x <- ifelse(rank_x == max(rank_x), Y[rank_x == (max(rank_x) - 1)], Y)
  return(new_x)
}

## Segundo, escribimos un estimador estilo DeclareDesign
diff_means_topcoded_fn <- function(data) {
  data$newY <- topcode_var(data$Y)
  obj <- lm_robust(newY ~ Z, data = data, se_type = "classical")
  res <- tidy(obj) %>% filter(term == "Z")
  return(res)
}

diff_means_topcoded <- declare_estimator(
  handler = label_estimator(diff_means_topcoded_fn),
  inquiry = estimandATE, label = "Top-coded Diff Means"
)
```

DeclareDesign: definiendo estimandos y estimadores

A continuación presentamos cómo funcionan los estimadores en DD utilizando datos simulados.

```
## Demuestra que el estimando funciona:  
estimandATE(sim_dat1)
```

```
      inquiry estimand  
1      ATE          54  
  
## Demuestra que los estimadores estiman
```

```
## Estimador 1 (diferencia de medias)  
diff_means(sim_dat1)[-c(1, 2, 10, 11)]
```

```
      estimate std.error statistic p.value conf.low conf.high df  
1    -123.6      258.6   -0.4781  0.6454   -719.9    472.7    8
```

```
## Estimador 2 (diferencia de medias truncada)  
diff_means_topcoded(sim_dat1)[-c(1, 2, 10, 11)]
```

```
      estimate std.error statistic p.value conf.low conf.high df  
1     -61.12      94.8   -0.6448  0.5371   -279.7    157.5    8
```

Simulemos una aleatorización

Recordemos cuál es el ATE real:

```
trueATE <- with(sim_dat1, mean(y1 - y0))  
with(sim_dat1, mean(Y_Z_1 - Y_Z_0))
```

```
[1] 54
```

Estas son las estimaciones de un experimento (una simulación de los datos):

```
## Dos formas de calcular el  
# estimador de la diferencia de medias  
est_diff_means_1 <- with(sim_dat1, mean(Y[Z == 1]) - mean(Y[Z == 0]))  
est_diff_means_2 <- coef(lm_robust(Y ~ Z,  
  data = sim_dat1,  
  se = "classical"  
))["Z"]  
c(est_diff_means_1, est_diff_means_2)
```

```
[1] -123.6 -123.6
```

Simulemos una aleatorización

Estas son las estimaciones de un experimento (una simulación de los datos):

```
## dos formas de calcular la diferencia de medias truncada
sim_dat1$rankY <- rank(sim_dat1$Y)
sim_dat1$Y_tc <- with(sim_dat1, ifelse(rankY == max(rankY),
  Y[rankY == (max(rankY) - 1)], Y
))
est_topcoded_1 <- with(sim_dat1, mean(Y_tc[Z == 1]) - mean(Y_tc[Z == 0]))
est_topcoded_2 <- coef(lm_robust(Y_tc ~ Z,
  data = sim_dat1,
  se = "classical"
))["Z"]
c(est_topcoded_1, est_topcoded_2)
```

```
[1] -22.38 -22.37
```

Ahora simulemos otra aleatorización y estimemos el ATE con los mismos estimadores

Ahora podemos hacer la estimación con los mismos estimadores utilizando una aleatorización **diferente**. Como pueden darse cuenta las respuestas difieren. Los estimadores están estimando el *mismo estimando* pero ahora están usando una aleatorización diferente.

```
# realizar una nueva asignación aleatoria en DeclareDesign
# esto produce un nuevo dataset con nuevas asignaciones
sim_dat1 <- draw_data(base_design)
sim_dat1$rankY <- rank(sim_dat1$Y)
sim_dat1$Y_tc <- with(sim_dat1, ifelse(rankY == max(rankY),
  Y[rankY == (max(rankY) - 1)], Y
))
est_topcoded_1 <- with(sim_dat1, mean(Y_tc[Z == 1]) - mean(Y_tc[Z == 0]))
est_topcoded_2 <- coef(lm_robust(Y_tc ~ Z,
  data = sim_dat1,
  se = "classical"
))["Z"]
c(est_topcoded_1, est_topcoded_2)
```

```
[1] -16.75 -16.75
```

¿Cómo se comportan nuestros estimadores para este diseño en particular?


Nuestras estimaciones varían según las aleatorizaciones. ¿Varían también nuestros dos estimadores de la misma manera?

```
## Combinar en un objeto diseño DeclareDesign
## Este tiene el diseño base, el estimando y luego nuestros dos estimadores
design_plus_ests <- base_design + estimandATE + diff_means + diff_means_topcoded
## Correr 10000 simulaciones (reasignaciones del tratamiento) y
## utilizar los dos estimadores (diff_means y diff_means_topcoded)
set.seed(12345)
diagnosis1 <- diagnose_design(design_plus_ests,
  bootstrap_sims = 0, sims = 10000
)
save(diagnosis1, file = "diagnosis1.rda")
```

	estimate	std.error	statistic	p.value	conf.low	conf.high	df	outcome
1	113.25	261.42	0.4332	0.67630	-489.6	716.1	8	Y
2	99.50	90.64	1.0977	0.30427	-109.5	308.5	8	newY
3	-127.37	258.71	-0.4924	0.63570	-724.0	469.2	8	Y
4	-66.12	94.38	-0.7006	0.50340	-283.8	151.5	8	newY
5	584.50	169.36	3.4512	0.00868	193.9	975.1	8	Y
6	-40.50	71.79	-0.5641	0.58812	-206.0	125.0	8	newY

¿Cómo se comportan nuestros estimadores para este diseño en particular?

¿Cómo interpretar esta gráfica (verdad = línea vertical discontinua)?



Cada punto gris es la estimación de un experimento posible (100 de las 10,000).
El punto negro marca el promedio de las estimaciones de cada estimador.

¿Cuál estimador se acerca más al valor real?

Un criterio para elegir entre los estimadores es elegir el estimador que siempre esté más **cerca del valor real**, independientemente de la aleatorización específica.

Un estimador “insesgado” es aquel para el que **el promedio de las estimaciones en los diseños repetidos** es igual al valor real (o $E_R(\hat{\tau}) = \bar{\tau}$). Un estimador insesgado no tiene “ningún error sistemático” pero tampoco nos garantiza que vamos a estar cerca del valor real.

Una cantidad para medir “la cercanía” al valor real es la **raíz del error cuadrático medio** (RMSE, por sus siglas en inglés), que registra las distancias cuadráticas entre la verdad y las estimaciones individuales.

¿Cuál estimador se acerca más al valor real?

¿Cuál estimador es mejor? (Uno está más cerca del valor real en promedio (RMSE) y es más preciso. El otro no tiene un error sistemático: es insesgado).

Estimator.1	Bias	RMSE	SD Estimate
Diff-Means/OLS	-0.47	245.46	245.47
Top-coded Diff Means	-52.00	101.68	87.38

No hay respuesta correcta.

Estimadores sesgados e insesgados

Resumen:

- Siempre podemos *decidir* sobre los estimandos y estimadores
- Un buen estimador debe funcionar bien independientemente de la aleatorización particular que se esté considerando de un diseño dado. El que *funcione bien* puede significar que sea “insesgado” y/o un “error cuadrático medio bajo” (o “consistente”, lo que quiere decir que a medida que el tamaño de la muestra aumenta el estimador se acerca más al valor real).
- Las simulaciones nos permiten saber qué tan bien trabaja un estimador para un estudio dado.

Sección 4

Aleatorización en bloques

Los experimentos aleatorizados en bloques son una colección de mini-experimentos

¿Cómo definir el estimando para el **ATE** en un experimento aleatorizado en bloques?

Si pensamos en el ATE a nivel de la unidad: $(1/N) \sum_{i=1}^N Y_i(1) - Y_i(0)$, podríamos re-expresar esta cantidad equivalentemente utilizando el ATE del bloque j , ATE_j , como a continuación:

$$ATE = \frac{1}{J} \sum_{j=1}^J \sum_{i=1}^{N_j} \frac{Y_i(1) - Y_i(0)}{N_j} = \sum_{j=1}^J \frac{N_j}{N} ATE_j$$

Y sería apenas lógico *estimar* esta cantidad reemplazando lo que sí podemos calcular:

$$\widehat{ATE} = \sum_{j=1}^J \frac{N_j}{N} \widehat{ATE}_j$$

Los experimentos aleatorizados en bloques son una colección de mini-experimentos

Podemos *definir* el error estándar del estimador promediando también los errores estándar dentro de cada bloque (si nuestros bloques son lo suficientemente grandes)

$$SE(\widehat{ATE}) = \sqrt{\sum_{j=1}^J (\frac{N_j}{N})^2 SE^2(\widehat{ATE}_j)}$$

Estimando el ATE en experimentos aleatorizados en bloques

Una opción de estimación es simplemente reemplazar ATE_j con $\widehat{ATE}$:

```
## Reducir el tamaño de la observación extrema para que las gráficas de abajo se vean mejor  
dat$y0[dat$y0 == 1000] <- 300  
dat$y1 <- with(dat, y0 + tau)  
dat$Y <- with(dat, Z * y1 + (1 - Z) * y0)  
with(dat, table(b, Z))
```

```
      Z  
b    0 1  
a    4 2  
b    2 2
```

Como podemos ver, tenemos 6 unidades en el bloque a, 2 de las cuales son asignadas al tratamiento, y 4 unidades en el bloque b, 2 de las cuales son asignadas al tratamiento.

El ATE en experimentos aleatorizados en bloques

Una opción de estimación es simplemente reemplazar ATE_j con $\widehat{ATE}$. Aquí primero vean cómo **calculamos** el ATE real:

```
datb <- dat %>%
  group_by(b) %>%
  summarize(
    nb = n(), pb = mean(Z), estateb = mean(Y[Z == 1]) - mean(Y[Z == 0]),
    ateb = mean(y1 - y0), .groups = "drop"
  )
datb
```

```
# A tibble: 2 x 5
  b      nb    pb estateb ateb
<chr> <int> <dbl>   <dbl> <dbl>
1 a         6 0.333    16.8     60
2 b         4 0.5     296.     45
```

```
## ATE real
with(dat, mean(y1 - y0))
```

```
[1] 54
```

```
## Otra forma de calcular el ATE real
with(datb, sum(ateb * (nb / sum(nb))))
```

```
[1] 54
```

Estimando el ATE en experimentos aleatorizados en bloques

Y podemos estimar el ATE total ajustando los pesos de acuerdo al tamaño de los bloques:

```
## Mostrar que difference_in_means usa los pesos por tamaño de bloque.
```

```
e1 <- with(datb, sum(estateb * (nb / sum(nb))))  
e1
```

```
[1] 128.2
```

```
dat <- dat %>%  
  group_by(b) %>%  
  mutate(  
    pb = mean(Z),  
    nbwt = Z / (pb) + (1 - Z) / (1 - pb)  
  )
```

```
e2 <- lm_robust(Y ~ Z, data = dat, weights = nbwt)  
coef(e2)[["Z"]]
```

```
[1] 128.3
```

Estimando el ATE en experimentos aleatorizados en bloques

```
## Un paquete de R más general (pero más nuevo): https://benbhansen-stats.github.io/propertee/index.html  
## Instalar una vez desde GitHub; omitir si ya está instalado para que la presentación se genere sin conexión  
if (!requireNamespace("propertee", quietly = TRUE)) {  
  remotes::install_github("benbhansen-stats/propertee", dependencies = TRUE)  
}  
library(propertee)  
blocked_design <- rct_spec(Z ~ unit_of_assignment(id) + block(b), data = dat)  
e2a <- lm_robust(Y ~ Z, data = dat, weights = ate(blocked_design, data = dat))  
coef(e2a)[["Z"]]
```

```
[1] 128.3
```

```
e2b <- lmitt(Y ~ 1, specification = blocked_design, data = dat, weights = "ate")  
coef(e2b)[["Z."]]
```

```
[1] 128.3
```

Estimando el ATE en experimentos aleatorizados en bloques

Tengan en cuenta que esto **no** es lo mismo que lo siguiente:

```
## Ignorando los bloques
e3 <- lm(Y ~ Z, data = dat)
coef(e3)[["Z"]]
```

```
[1] 156.8
```

```
## Luego usando "pesos de precisión" ("precision weights")
e4 <- lm(Y ~ Z + block, data = dat)
coef(e4)[["Z"]]
```

```
[1] 136.2
```

```
e4a <- lm_robust(Y ~ Z, fixed_effects = ~block, data = dat)
coef(e4a)[["Z"]]
```

```
[1] 136.2
```

```
## O con el argumento absorb=TRUE:
e4b <- lmitt(Y ~ 1, specification = blocked_design, data = dat, absorb = TRUE)
coef(e4b)[["Z."]]
```

```
[1] 136.2
```

¿En qué se diferencian? (El primero ignora los bloques. El segundo usa un conjunto de pesos diferente, creado usando las variables de “efectos fijos” o “indicadores” o variables “dummy”)

¿Cuál estimador deberíamos usar?

Cada uno de los tres estimadores produce una estimación diferente (asumiendo que todos intentan estimar el mismo estimando):

```
c(coef(e2)[["Z"]], coef(e3)[["Z"]], coef(e4)[["Z"]])
```

```
[1] 128.3 156.8 136.2
```

¿Cuál estimador deberíamos usar?

Cada uno de los tres estimadores produce una estimación diferente (asumiendo que todos intentan estimar el mismo estimando):

¿Cuál estimador deberíamos usar para este diseño? Podemos responder esta pregunta simulando en DeclareDesign.

```
## declarar un nuevo diseño base que incluya el indicador de bloque b
base_design_blocks <-
  # declarar la población
  declare_population(dat[, c("b", "y0", "y1", "id")]) +
  # Indicarle a DD que b son bloques y
  # 2 unidades son tratadas en cada bloque
  declare_assignment(
    Z = conduct_ra(N = N, m = 2, blocks = b),
    Z_cond_prob = obtain_condition_probabilities(assignment = Z, m = 2)
  ) +
  # relación entre resultados potenciales y variables de interés
  declare_potential_outcomes(Y ~ Z * y1 + (1 - Z) * y0) +
  # variable de resultado observada y asignación al tratamiento
  declare_reveal(Y, Z)
```

¿Cuál estimador deberíamos usar?

```
# El estimando es el efecto promedio del tratamiento
estimandATEb <- declare_inquiry(ATE = mean(Y_Z_1 - Y_Z_0))

# dos estimadores distintos (los demás se definen más abajo)
est1 <- declare_estimator(Y ~ Z,
  inquiry = estimandATEb, .method = lm_robust,
  label = "Ignores Blocks"
)
est2 <- declare_estimator(Y ~ Z,
  inquiry = estimandATEb, .method = difference_in_means, blocks = b,
  label = "DiM: Block-Size Weights"
)
```

¿Cuál estimador deberíamos usar?

```
nbwt_est_fun <- function(data) {  
  data <- data %>%  
    group_by(b) %>%  
    mutate(  
      pb = mean(Z),  
      newnbwt = (Z / pb) + ((1 - Z) / (1 - pb))  
    )  
  obj <- lm_robust(Y ~ Z, data = data, weights = newnbwt)  
  res <- tidy(obj) %>% filter(term == "Z")  
  return(res)  
}  
  
est3 <- declare_estimator(  
  handler = label_estimator(nbwt_est_fun), inquiry = estimandATEb,  
  label = "LM: Block Size Weights"  
)
```


¿Cuál estimador deberíamos usar?

```
propertee_est_fun <- function(data) {  
  des <- rct_spec(Z ~ unit_of_assignment(id) + block(b), data = data)  
  obj <- lm_robust(Y ~ Z, data = data, weights = ate(des, data = data))  
  res <- tidy(obj) %>% filter(term == "Z")  
  return(res)  
}  
  
est3a <- declare_estimator(  
  handler = label_estimator(propertee_est_fun), inquiry = estimandATEb,  
  label = "Propertee: Block Size Weights"  
)
```

¿Cuál estimador deberíamos usar?


```
# dos estimadores más
est4 <- declare_estimator(Y ~ Z,
  inquiry = estimandATEb,
  .method = lm_robust, fixed_effects = ~b, label = "Precision Weights"
)
est5 <- declare_estimator(Y ~ Z + b,
  inquiry = estimandATEb,
  .method = lm_robust, label = "Precision Weights (LSDV)"
)
```

```
# El nuevo objeto del diseño tiene
# el diseño base, el estimando y seis estimadores
design_blocks <- base_design_blocks + estimandATEb +
  est1 + est2 + est3 + est3a + est4 + est5
```

Lo que haremos ahora es correr 10,000 simulaciones (el tratamiento se reasigna 10,000 veces) y resumir las estimaciones producidas por cada uno de estos seis estimadores.

¿Cuál estimador deberíamos usar?

¿Cómo interpretar esta gráfica?



Cada punto gris es la estimación de un experimento posible (100 de las 10,000); el punto negro marca el promedio.

¿Cuál estimador se acerca más al valor real?

¿Cuál estimador funciona mejor para estos datos y diseño en particular?

Estimator.1	Bias	RMSE	SD Estimate	Coverage
DiM: Block-Size Weights	1.26	64.86	64.85	0.75
Ignores Blocks	20.45	68.99	65.89	0.98
LM: Block Size Weights	1.26	64.86	64.85	0.99
Precision Weights	0.92	68.35	68.35	0.93
Precision Weights (LSDV)	0.92	68.35	68.35	0.93
Propertee: Block Size Weights	1.26	64.86	64.85	0.99

¿Cuál es el problema con la cobertura?

Noten que el error estándar estimado de `difference_in_means` es demasiado bajo:

```
# A tibble: 6 x 3
```

	estimator	mean_est_se	sd_est
	<chr>	<dbl>	<dbl>
1	DiM: Block-Size Weights	61.8	64.8
2	Ignores Blocks	74.5	65.9
3	LM: Block Size Weights	73.9	64.8
4	Precision Weights	69.5	68.3
5	Precision Weights (LSDV)	69.5	68.3
6	Propertee: Block Size Weights	73.9	64.8

¿Cuándo es grande el sesgo de los “pesos de precisión”?

- El estimador de efectos fijos / LSDV pondera cada bloque por $n_j p_j (1 - p_j)$ — los “pesos de precisión” — en vez de ponderar por el tamaño n_j . Si la proporción tratada p_j es igual en todos los bloques, los dos conjuntos de pesos coinciden y no hay sesgo.
- El sesgo aparece cuando se cumplen *dos* condiciones a la vez: p_j varía entre bloques y el ATE_j varía junto con p_j .
- En nuestro ejemplo el sesgo fue minúsculo (0.92 sobre un ATE de 54): los ATEs por bloque son parecidos (60 y 45) y los dos conjuntos de pesos casi iguales (.57/.43 contra .60/.40).
- Construyamos dos diseños: uno donde las dos condiciones se cumplen con fuerza (diseño A) y uno donde el efecto es igual en todos los bloques (diseño B).

Dos diseños para ver el sesgo (y la ganancia de precisión) I

```
## Dos bloques de 40 unidades. En B1 tratamos a la mitad (20 de 40);  
## en B2 tratamos a muy pocos (2 de 40): p_1 = .5, p_2 = .05.  
## Los pesos de precisión resultan .84/.16; los de tamaño, .5/.5.  
set.seed(20260729)  
datAB <- data.frame(  
  b = rep(c("B1", "B2"), each = 40),  
  y0 = rnorm(80, mean = 0, sd = 5),  
  id = 1:80  
)  
## Diseño A: el ATE del bloque varía JUNTO con p_j (10 en B1, 0 en B2)  
datAB$tau_A <- ifelse(datAB$b == "B1", 10, 0)  
## Diseño B: el mismo efecto en los dos bloques  
datAB$tau_B <- 10  
assign_AB <- declare_assignment(  
  Z = conduct_ra(N = 80, blocks = b, block_m = c(20, 2))  
)
```

Dos diseños para ver el sesgo (y la ganancia de precisión) II

```
est_dim <- declare_estimator(Y ~ Z,
  .method = difference_in_means, blocks = b,
  inquiry = "ATE", label = "DiM: Block-Size Weights"
)
est_fe <- declare_estimator(Y ~ Z,
  .method = lm_robust, fixed_effects = ~b,
  inquiry = "ATE", label = "Precision Weights (FE)"
)
design_A <- declare_population(datAB) + assign_AB +
  declare_potential_outcomes(Y ~ Z * (y0 + tau_A) + (1 - Z) * y0) +
  declare_reveal(Y, Z) + declare_inquiry(ATE = mean(tau_A)) +
  est_dim + est_fe
design_B <- declare_population(datAB) + assign_AB +
  declare_potential_outcomes(Y ~ Z * (y0 + tau_B) + (1 - Z) * y0) +
  declare_reveal(Y, Z) + declare_inquiry(ATE = mean(tau_B)) +
  est_dim + est_fe
```


Dos diseños para ver el sesgo (y la ganancia de precisión) III

10,000 simulaciones de cada diseño:

Design	Estimator	Mean Estimand	Bias	RMSE	SD Estimate
design_A	DiM: Block-Size Weights	5.00	0.03	2.08	2.08
design_A	Precision Weights (FE)	5.00	3.42	3.73	1.50
design_B	DiM: Block-Size Weights	10.00	-0.00	2.09	2.09
design_B	Precision Weights (FE)	10.00	-0.01	1.49	1.50

Lecciones de los dos diseños

- En el diseño A los pesos de precisión producen un sesgo de alrededor de 3.4 sobre un ATE verdadero de 5 — un error sistemático de casi el 70 % que *no* desaparece al crecer la muestra. Los pesos por tamaño de bloque quedan insesgados.
- En el diseño B — el mismo diseño, pero con el efecto igual en los dos bloques — ambos estimadores son insesgados y los pesos de precisión cumplen su promesa: una desviación estándar de alrededor de 1.5 contra 2.1, porque le restan peso al bloque donde solo 2 unidades fueron tratadas.
- La lección: cuando p_j difiere entre bloques, los pesos por tamaño de bloque son la opción segura para estimar el ATE; los pesos de precisión compran menor varianza al precio de un sesgo que depende de cuánto varíe el ATE_j con p_j — algo que no podemos verificar en los datos observados.

Sección 5

Aleatorización por conglomerados

En los experimentos aleatorizados por conglomerados, las unidades se asignan al azar al tratamiento como grupo (conglomerado) I

- **Ejemplo 1:** una intervención se asigna al azar entre vecindarios, lo que quiere decir que **todos** los hogares de un vecindario se asignarán a la misma condición de tratamiento, pero a diferentes vecindarios se les asignarán diferentes condiciones de tratamiento.
- **Ejemplo 2:** una intervención se asigna al azar entre personas y después del tratamiento se miden datos de cada persona cuatro veces, lo que quiere decir que nuestro conjunto de datos contiene cuatro filas por persona.
- **Esto no es un ejemplo 1:** Se seleccionan vecindarios para un estudio. Dentro de cada vecindario, aproximadamente la mitad de las personas están asignadas al tratamiento y la otra mitad al control. (¿Qué tipo de estudio es este? No es un estudio aleatorizado por conglomerados).
- **Esto no es un ejemplo 2:** una intervención se asigna al azar a algunos vecindarios y a otros no, entre las variables de interés se encuentran la confianza en el gobierno a nivel del vecindario y el área total de tierra en el vecindario destinada a jardines. (A veces, un experimento aleatorizado por conglomerados se puede convertir en un experimento aleatorizado simple. O puede contener más de una posible forma para hacer análisis e interpretación).

En los experimentos aleatorizados por conglomerados, las unidades se asignan al azar al tratamiento como grupo (conglomerado) II

¿En qué podrían diferenciarse la distribución de una estadística de prueba y estimadores en un experimento aleatorizado a nivel individual y en uno de conglomerados?

Estimación del ATE en experimentos aleatorizados por conglomerados

Problemas de sesgo en experimentos aleatorizados por conglomerados:

- Cuando los conglomerados son del mismo tamaño, el estimador de diferencia de medias que usamos habitualmente es insesgado.
- Pero hay que tener cuidado cuando los conglomerados tienen un número diferente de unidades o si hay muy pocos conglomerados ya que los efectos del tratamiento podrían estar correlacionados con el tamaño del conglomerado.
- Cuando el tamaño del conglomerado está relacionado con los resultados potenciales, el estimador habitual de diferencias de medias está sesgado.

<https://declaredesign.org/blog/bias-cluster-randomized-trials.html>

Estimación del error estándar para el ATE en experimentos aleatorizados por conglomerados I

- **Inferencias estadísticas engañosas:** En general, el error estándar usado por defecto subestima la incertidumbre en dichos diseños y por lo tanto produce pruebas con tasas de falsos positivos demasiado altas (o, equivalentemente, la cobertura de los intervalos de confianza puede ser demasiado baja).
- Los “errores estándar robustos para conglomerados” implementados en softwares comunes funcionan bien **cuando el número de conglomerados es alto** (más de 50 en algunos casos).
- Los errores estándar para conglomerados predeterminados en `lm_robust` (SE de CR2) funcionan mejor que los disponibles en STATA (al momento en el que se escribe esta presentación).
- El wild-bootstrap ayuda a controlar las tasas de error, pero se pierde potencia estadística mucho más de lo que quizás sea necesario para un estudio aleatorizado por conglomerados donde se pueden hacer inferencias directamente.

Estimación del error estándar para el ATE en experimentos aleatorizados por conglomerados II

- En caso de no estar seguro, se pueden calcular valores p mediante simulación directa (inferencia directa basada en la aleatorización) para evaluar si las estimaciones robustas para conglomerados son correctas.

En general, en caso de que se tenga alguna inquietud o duda es conveniente simular para estudiar el desempeño de sus estimadores, pruebas e intervalos de confianza.

Un ejemplo de estimación

Supongamos que tenemos datos provenientes de 10 conglomerados con 100 personas (en 2 conglomerados) o 10 personas por grupo (en 8 conglomerados). El tamaño total de los datos es 280.

```
# A tibble: 6 x 6
# Groups:   clus_id [2]
  clus_id indiv Y_Z_0 Y_Z_1      Z      Y
  <chr>    <chr> <dbl> <dbl> <int> <dbl>
1 01      010   4.51  4.61     0  4.51
2 01      035   4.63  4.73     0  4.63
3 01      068   4.76  4.86     0  4.76
4 03      205   3.13  4.13     1  4.13
5 03      206   2.41  3.41     1  3.41
6 03      208   2.95  3.95     1  3.95
```

Un ejemplo de estimación

¿Cuál estimador deberíamos utilizar? ¿Cuál prueba deberíamos utilizar? ¿En qué nos deberíamos basar para elegir entre alternativas?

```
lmc1 <- lm_robust(Y ~ Z, data = dat1)
lmc2 <- lm_robust(Y ~ Z, clusters = clus_id, data = dat1)
lmc3 <- lm_robust(Y ~ Z + cl_sizeF, clusters = clus_id, data = dat1)
tidy(lmc1)[2, ]
```

	term	estimate	std.error	statistic	p.value	conf.low	conf.high	df	outcome
2	Z	0.3024	0.1207	2.504	0.01284	0.06471	0.5401	278	Y

```
tidy(lmc2)[2, ]
```

	term	estimate	std.error	statistic	p.value	conf.low	conf.high	df	outcome
2	Z	0.3024	1.079	0.2804	0.796	-2.969	3.574	3.282	Y

```
tidy(lmc3)[2, ]
```

	term	estimate	std.error	statistic	p.value	conf.low	conf.high	df	outcome
2	Z	0.3024	0.306	0.9882	0.4386	-1.194	1.799	1.769	Y

Simular para evaluar estimadores y pruebas

Si observan el código de las diapositivas, verán que simulamos el diseño muchas veces, calculando cada vez una estimación y un intervalo de confianza para diferentes estimadores del ATE.

¿Qué podemos aprender de esta tabla? (¿Cobertura? ¿sd_estimate versus mean_se?)

Tabla 1: Desempeño de estimadores y pruebas con 10000 simulaciones del diseño aleatorizado por conglomerados para diferentes estimadores e intervalos de confianza

estimator	coverage	sd_estimate	mean_se
Y~Z*I(clus_size-mean(clus_size)), CR2	0.75	1.60	0.06
Y~Z, cl_size fe, CR2	0.75	0.36	0.30
Y~Z, CR2	0.56	1.09	0.72
Y~Z, HC2	0.56	1.09	0.13
Y~Z, IID	0.56	1.09	0.12
Y~Z*I(cl_size-mean(cl_size)), CR2	0.75	0.36	0.30
Y~Z+cl_sizeF, CR2	0.56	1.24	0.83

Simular para evaluar estimadores y pruebas


¿Qué podemos aprender de esta tabla? (¿Sesgo? ¿Cercanía al valor real?)

Tabla 2: Desempeño de estimadores y pruebas con 10000 simulaciones del diseño aleatorizado por conglomerados para diferentes estimadores e intervalos de confianza

estimator	bias	rmse
$Y \sim Z * I(\text{clus_size} - \text{mean}(\text{clus_size})), \text{CR2}$	0.819	1.799
$Y \sim Z, \text{cl_size fe}, \text{CR2}$	0.285	0.458
$Y \sim Z, \text{CR2}$	0.128	1.097
$Y \sim Z, \text{HC2}$	0.128	1.097
$Y \sim Z, \text{IID}$	0.128	1.097
$Y \sim Z * I(\text{cl_size} - \text{mean}(\text{cl_size})), \text{CR2}$	0.285	0.458
$Y \sim Z + \text{cl_sizeF}, \text{CR2}$	-0.016	1.243

Simular para evaluar estimadores y pruebas

¿Cómo podemos interpretar esta gráfica?



Cada punto gris es la estimación de un experimento posible (100 de las 10,000); el punto negro marca el promedio.

Resumen sobre estimación y pruebas en estudios aleatorizados por conglomerados

- Los ensayos aleatorios por conglomerados conllevan una serie de dificultades especiales para las formas estándar de estimación y prueba.
- Si la aleatorización se hace al nivel del conglomerado, la incertidumbre que surge de la aleatorización es también a nivel del conglomerado.
- Cuando tenemos suficientes conglomerados, los errores estándar “robustos para conglomerados” pueden ayudarnos a producir intervalos de confianza con la cobertura correcta. **Los errores estándar robustos para conglomerados requieren que haya muchos conglomerados.**
- Si el tamaño del conglomerado (o alguna característica) está relacionado con el tamaño del efecto, entonces la estimación puede estar sesgada (y necesitamos ajustar de alguna manera).

Sección 6

Variables de resultado binarias

Variables de resultado binarias: Definiendo datos en DeclareDesign para las simulaciones

```
# tamaño de la población
N <- 100
# declarar la población
thepop_bin <- declare_population(
  N = N, x1 = draw_binary(prob = .5, N = N),
  x2 = rnorm(N)
)
# declarar los resultados potenciales en la escala log-odds: x1 predice
# FUERTEMENTE el resultado (coeficiente 3). Esa covariable fuerte es la
# que separa el odds ratio condicional del marginal (no-colapsabilidad),
# el sesgo del que nos advierte Freedman (2008) más abajo.
thepo_bin <- declare_potential_outcomes(Y ~ rbinom(
  n = N, size = 1,
  prob = plogis(-1.5 + 1 * Z + 3 * x1)
))
# dos cantidades objetivo posibles:
# diferencia de medias o diferencia de log-odds
thetarget_ate <- declare_inquiry(ate = mean(Y_Z_1 - Y_Z_0))
thetarget_logodds <- declare_inquiry(
  logodds = log(mean(Y_Z_1) / (1 - mean(Y_Z_1))) -
    log(mean(Y_Z_0) / (1 - mean(Y_Z_0)))
)
```


Variables de resultado binarias: Definiendo datos en DeclareDesign para las simulaciones

```
# declarar cómo se asigna el tratamiento
# m unidades se asignan a los niveles del tratamiento Z
theassign_bin <- declare_assignment(Z = conduct_ra(N = N, m = floor(N / 3)))
# declarar cuáles variables se revelan para distintos niveles de Z
thereveal_bin <- declare_reveal(Y, Z)
# reuniendo todo: población, resultados potenciales, asignación,
## variable Y conectada a Z
des_bin <- thepop_bin + thepo_bin + theassign_bin + thereveal_bin
# una realización de los datos (se asigna el tratamiento al azar una vez)
set.seed(12345)
dat2 <- draw_data(des_bin)
```

Variables de resultado binarias: Estimandos I

¿Cómo interpretar las siguientes cantidades reales o estimandos? (Y_{Z_1} , Y_{Z_0} son resultados potenciales, Y es observada, x_1 , x_2 son covariables, Z es la asignación al tratamiento. En este caso $N=100$.)

```
## Explorar primeras 6 observaciones  
head(dat2[, -7])
```

	ID	x1	x2	Y_{Z_0}	Y_{Z_1}	Z
1	001	1	-0.54039	1	1	0
2	002	1	1.94769	1	1	0
3	003	1	0.05359	1	1	0
4	004	1	0.35166	1	1	1
5	005	0	-0.67098	0	1	0
6	006	0	0.27795	0	0	1

Variables de resultado binarias: Estimandos II

¿Cómo interpretar las siguientes cantidades reales o estimandos? (Y_{Z_1} , Y_{Z_0} son resultados potenciales, Y es observada, x_1 , x_2 son covariables, Z es la asignación al tratamiento. En este caso $N=100$.)

```
ate_bin <- with(dat2, mean(Y_Z_1 - Y_Z_0))
bary1 <- mean(dat2$Y_Z_1)
bary0 <- mean(dat2$Y_Z_0)
diff_log_odds_bin <- with(
  dat2,
  log(bary1 / (1 - bary1)) - log(bary0 / (1 - bary0))
)
c(
  bary1 = bary1, bary0 = bary0, true_ate = ate_bin,
  true_diff_log_odds = diff_log_odds_bin
)
```

bary1	bary0	true_ate	true_diff_log_odds
0.6800	0.5300	0.1500	0.6336

Variables de resultado binarias: Estimandos III

¿Quieren estimar la diferencia en log-odds?

$$\delta = \log \frac{\bar{y}_1}{1 - \bar{y}_1} - \log \frac{\bar{y}_0}{1 - \bar{y}_0} \quad (1)$$

¿o la diferencia en proporciones?

$$\bar{\tau} = \bar{y}_1 - \bar{y}_0 \quad (2)$$

Recuerden que $\bar{y}_1$ es la *proporción* de $y_1 = 1$ en los datos.

Freedman (2008b) nos muestra que el estimador del coeficiente logit ajustado por covariables es un estimador sesgado del estimando de la diferencia en los log-odds. Así mismo también presenta un estimador consistente para ese mismo estimando.

Es claro que la diferencia de proporciones en la muestra debería ser un estimador insesgado de la diferencia de proporciones.

Un ejemplo de estimación I

¿Cómo debemos interpretar las siguientes estimaciones? (¿Cuáles son los supuestos que el estimador de diferencia de medias requiere? ¿Cuáles son los supuestos que el estimador de la regresión logística requiere?)

```
lmbin1 <- lm_robust(Y ~ Z, data = dat2)
glmbin1 <- glm(Y ~ Z, data = dat2, family = binomial(link = "logit"))

broom::tidy(lmbin1)[2, ]
```

	term	estimate	std.error	statistic	p.value	conf.low	conf.high	df	outcome
2	Z	-0.05156	0.1067	-0.4831	0.6301	-0.2634	0.1603	98	Y

```
broom::tidy(glmbin1)[2, ]
```

A tibble: 1 x 5

	term	estimate	std.error	statistic	p.value
	<chr>	<dbl>	<dbl>	<dbl>	<dbl>
1	Z	-0.211	0.429	-0.491	0.623

Un ejemplo de estimación II

¿Qué hay con las covariables? ¿Por qué usamos covariables en experimentos aleatorios?

```
lmbin2 <- lm_robust(Y ~ Z + x1, data = dat2)
glmbin2 <- glm(Y ~ Z + x1, data = dat2, family = binomial(link = "logit"))

tidy(lmbin2)[2, ]
```

```
term estimate std.error statistic p.value conf.low conf.high df outcome
2      Z  0.04569   0.07911    0.5776  0.5649  -0.1113   0.2027  97         Y

tidy(glmbin2)[2, ]
```

```
# A tibble: 1 x 5
  term estimate std.error statistic p.value
  <chr>      <dbl>      <dbl>      <dbl>    <dbl>
1 Z         0.344      0.593      0.580    0.562
```

Un ejemplo de estimación III

Ahora comparemos nuestras estimaciones

```
c(  
  dim = coef(lmbin1)[["Z"]],  
  dim_x1 = coef(lmbin2)[["Z"]],  
  glm = coef(glmbin1)[["Z"]],  
  glm_x1 = coef(glmbin2)[["Z"]]  
)
```

dim	dim_x1	glm	glm_x1
-0.05156	0.04569	-0.21072	0.34357

Logit sin ajustar versus logit ajustado: apuntan a blancos distintos

- La logística con solo Z está *saturada*: su coeficiente es exactamente la diferencia de log-odds observada, $\text{logit}(\bar{Y}_{Z=1}) - \text{logit}(\bar{Y}_{Z=0})$. Es un estimador consistente de la diferencia marginal δ .
- Al agregar una covariable cambia el blanco: el coeficiente de Z en $\text{glm}(Y \sim Z + x_1)$ apunta a la diferencia de log-odds *manteniendo fija* x_1 — una cantidad condicional.
- Los odds ratios no son *colapsables*: la diferencia condicional de log-odds queda más lejos de cero que la marginal, aun sin confusión. Por eso el coeficiente ajustado es un estimador sesgado de δ , y esa brecha no se achica al crecer N (Freedman 2008b).
- La reparación de Freedman (“plug-in”): con el *mismo* modelo ajustado, predecir la probabilidad de cada unidad bajo $Z = 1$ y bajo $Z = 0$, promediar, y tomar la diferencia de log-odds. Ese estimador vuelve a la escala marginal y es consistente.

Un ejemplo de estimación: Los estimadores de Freedman I

Sin covariables:

```
freedman_plugin_estfn1 <- function(data) {  
  glmbin <- glm(Y ~ Z, data = data, family = binomial(link = "logit"))  
  preddat <- data.frame(Z = rep(c(0, 1), nrow(data)))  
  preddat$yhat <- predict(glmbin, newdata = preddat, type = "response")  
  bary1 <- mean(preddat$yhat[preddat$Z == 1])  
  bary0 <- mean(preddat$yhat[preddat$Z == 0])  
  diff_log_odds <- log(bary1 / (1 - bary1)) - log(bary0 / (1 - bary0))  
  return(data.frame(estimate = diff_log_odds, estimator = "Freedman:Z", inquiry = "logodds"))  
}
```

```
freedman_plugin_lm_estfn1 <- function(data) {  
  lmbin <- lm(Y ~ Z, data = data)  
  preddat <- data.frame(Z = rep(c(0, 1), nrow(data)))  
  preddat$yhat <- predict(lmbin, newdata = preddat)  
  bary1 <- mean(preddat$yhat[preddat$Z == 1])  
  bary0 <- mean(preddat$yhat[preddat$Z == 0])  
  diff_log_odds <- log(bary1 / (1 - bary1)) - log(bary0 / (1 - bary0))  
  return(data.frame(estimate = diff_log_odds, estimator = "Freedman,LM:Z", inquiry = "logodds"))  
}
```

Un ejemplo de estimación: Los estimadores de Freedman II

Con covariables:

```
freedman_plugin_estfn2 <- function(data) {  
  N <- nrow(data)  
  glmbin <- glm(Y ~ Z + x1, data = data, family = binomial(link = "logit"))  
  preddat <- data.frame(Z = rep(c(0, 1), each = N))  
  preddat$x1 <- rep(data$x1, 2)  
  preddat$yhat <- predict(glmbin, newdata = preddat, type = "response")  
  bary1 <- mean(preddat$yhat[preddat$Z == 1])  
  bary0 <- mean(preddat$yhat[preddat$Z == 0])  
  diff_log_odds <- log(bary1 / (1 - bary1)) - log(bary0 / (1 - bary0))  
  return(data.frame(estimate = diff_log_odds, estimator = "Freedman:Z,x1", inquiry = "logodds"))  
}
```

```
freedman_plugin_lm_estfn2 <- function(data) {  
  N <- nrow(data)  
  lmbin <- lm(Y ~ Z + x1, data = data)  
  preddat <- data.frame(Z = rep(c(0, 1), each = N))  
  preddat$x1 <- rep(data$x1, 2)  
  preddat$yhat <- predict(lmbin, newdata = preddat)  
  bary1 <- mean(preddat$yhat[preddat$Z == 1])  
  bary0 <- mean(preddat$yhat[preddat$Z == 0])  
  diff_log_odds <- log(bary1 / (1 - bary1)) - log(bary0 / (1 - bary0))  
  return(data.frame(estimate = diff_log_odds, estimator = "Freedman,LM:Z,x1", inquiry = "logodds"))  
}
```

Un ejemplo de estimación: Los estimadores de Freedman II

Ahora comparemos las estimaciones de los ocho estimadores diferentes

dim	dim_x1	glm	glm_x1	freedman	freeman_x1	freedman_lm	freeman_lm_x1
-0.05156	0.04569	-0.21072	0.34357	-0.21072	0.18175	-0.21072	0.18873

tmle: una manera fácil de implementar el plug-in de Freedman

- El paquete `tmle` implementa la estimación por máxima verosimilitud dirigida (targeted maximum likelihood). Su primer paso es exactamente el plug-in de Freedman: ajustar una logística (`Qform`), predecir cada unidad bajo $Z = 1$ y bajo $Z = 0$, y promediar.
- Su segundo paso (“targeting”) corrige el ajuste inicial usando la probabilidad de tratamiento. En un experimento aleatorizado esa probabilidad es constante (`gform = A ~ 1`), y con una logística con intercepto y término de tratamiento ajustada por máxima verosimilitud la corrección resulta exactamente cero: la “covariable inteligente” del targeting ya es una combinación lineal de los scores de la logística.
- Resultado: `tmle()` reporta el *mismo* número que el plug-in de Freedman — y además entrega errores estándar e intervalos de confianza basados en la curva de influencia, que nuestras funciones escritas a mano no dan.

tmle = plug-in de Freedman: verificación numérica

Los dos estimadores del mismo estimando de log-odds, con el mismo modelo ajustado ($Y \sim Z + x_1$):

```
c(  
  freedman_plugin = freedman_plugin_estfn2(dat2)[["estimate"]],  
  tmle_log_odds = tmle2$estimates$OR$log.psi  
)
```

```
freedman_plugin  tmle_log_odds  
      0.1818      0.1818
```

```
## tmle agrega el intervalo de confianza para el odds ratio:  
tmle2$estimates$OR$CI
```

```
[1] 0.6328 2.2731
```

```
## y también reporta la diferencia de proporciones (ATE) con su intervalo:  
c(tmle_ate = tmle2$estimates$ATE$psi)
```

```
tmle_ate  
  0.04405
```

```
tmle2$estimates$ATE$CI
```

```
[1] -0.1097  0.1978
```

Un ejemplo del uso de DeclareDesign para evaluar estimadores I


```
# declarar 4 estimadores para DD
# primer estimador: regresión lineal con ATE como cantidad objetivo
estb1 <- declare_estimator(Y ~ Z,
  .method = lm_robust, label = "lm1:Z",
  inquiry = thetarget_ate
)
# segundo estimador: regresión lineal con covariables con ATE como cantidad objetivo
estb2 <- declare_estimator(Y ~ Z + x1,
  .method = lm_robust, label = "lm1:Z,x1",
  inquiry = thetarget_ate
)
# tercer estimador: regresión logística con log odds como cantidad objetivo
estb3 <- declare_estimator(Y ~ Z,
  .method = glm, family = binomial(link = "logit"),
  label = "glm1:Z", inquiry = thetarget_logodds
)
# cuarto estimador: regresión logística con covariables con log odds como cantidad objetivo
estb4 <- declare_estimator(Y ~ Z + x1,
  .method = glm, family = binomial(link = "logit"),
  label = "glm1:Z,x1", inquiry = thetarget_logodds
)
```

Un ejemplo del uso de DeclareDesign para evaluar estimadores II

```
# Reuniendo todo des_bin es:  
# la población, los resultados potenciales,  
# la asignación, los valores realizados de Y conectados a Z.  
# Además, le agregamos dos cantidades objetivo y nueve estimadores.  
des_bin_plus_est <- des_bin + thetarget_ate + thetarget_logodds +  
  estb1 + estb2 + estb3 + estb4 + custom_tmle_estimator +  
  freedman_est1 + freedman_est2 + freedman_est3 + freedman_est4
```

Usando simulación para evaluar estimadores

¿Cómo interpretar esta gráfica? (Las diferencias en escala dificultan la interpretación).



La línea discontinua marca el valor verdadero de cada estimando.

Los puntos grises son 100 de las 1,000 estimaciones; el punto negro, su promedio.

¿Qué estimador está más cerca del valor real?


¿Qué estimador funciona mejor para este diseño y estos datos?

Tabla 3: Desempeño de estimadores y pruebas con 1000 simulaciones del diseño aleatorizado para diferentes estimadores.

est	estimand	bias	rmse
Freedman,LM:Z	logodds	0.017	0.405
Freedman,LM:Z,x1	logodds	0.018	0.292
Freedman:Z	logodds	0.017	0.405
Freedman:Z,x1	logodds	0.018	0.293
glm1:Z	logodds	0.017	0.405
glm1:Z,x1	logodds	0.437	0.674
lm1:Z	ate	0.000	0.090
lm1:Z,x1	ate	0.001	0.065
tmle:Z,x1	logodds	0.018	0.293

El sesgo del coeficiente logit ajustado no disminuye con N

El mismo diseño de arriba con 500 simulaciones por cada N: el sesgo del coeficiente ajustado se queda quieto mientras los otros dos estimadores convergen al estimando.



Sección 7

Ajuste de covarianza

En experimentos las covariables sirven para la precisión — pero “controlar por” no es gratis

- La aleatorización equilibra las covariables en promedio: no necesitamos x para identificar el ATE. Aun así, una covariable que predice el resultado puede achicar nuestros errores estándar — por eso ajustamos.
- El reflejo de los estudios observacionales — reportar el coeficiente de Z en $\text{lm}(Y \sim Z + x)$ — es otro estimador, y Freedman (2008a) mostró que es un estimador **sesgado** del ATE. El sesgo disminuye cuando N crece (Lin 2013), así que la pregunta es cuándo importa y qué hacer al respecto.
- Plan: construir un experimento pequeño donde el sesgo se vea, comparar cuatro estimadores y luego observar cómo el sesgo se desvanece a medida que el experimento crece.

Un experimento pequeño con una covariable asimétrica que predice el resultado

```
set.seed(5)
N3 <- 20 # el tamaño de un piloto o de un análisis a nivel de conglomerado
## Una covariable asimétrica: la mayoría de las unidades son pequeñas,
## unas pocas quedan lejos en la cola
x <- exp(rnorm(N3, mean = 0, sd = 1))
## x predice fuertemente el resultado bajo control, así que
## el ajuste promete una ganancia real de precisión
y0 <- x + rnorm(N3, sd = 0.5)
## Los efectos son más grandes justo donde x es extrema. El sesgo de
## Freedman crece con esta covarianza entre apalancamiento
## (leverage) y tamaño del efecto
y1 <- y0 + 0.75 * x^2
dat3 <- data.frame(x = x, y0 = y0, y1 = y1)
trueATE3 <- mean(dat3$y1 - dat3$y0)
c(ATE = trueATE3, cor_x_y0 = cor(dat3$x, dat3$y0), max_x = max(dat3$x))
```

ATE	cor_x_y0	max_x
2.5112	0.9275	5.5369

Asignaremos 10 de las 20 unidades al tratamiento:

```
base_design_cov <- declare_population(dat3) +
  declare_assignment(Z = conduct_ra(N = N, m = 10)) +
  declare_potential_outcomes(Y ~ Z * y1 + (1 - Z) * y0) +
  declare_reveal(Y, Z)
```

Tres estimadores conocidos del mismo ATE

```
estimandATEc <- declare_inquiry(ATE = mean(Y_Z_1 - Y_Z_0))
est_c1 <- declare_estimator(Y ~ Z,
  inquiry = estimandATEc, .method = difference_in_means,
  label = "Diff means: ignores x"
)
est_c2 <- declare_estimator(Y ~ Z + x,
  inquiry = estimandATEc, .method = lm_robust,
  label = "Y~Z+x: 'controls for' x"
)
## La reparación de Lin a la crítica de eficiencia de Freedman: centrar
## x, interactuar con Z y usar errores estándar robustos
est_c3 <- declare_estimator(Y ~ Z,
  covariates = ~x, inquiry = estimandATEc, .method = lm_lin,
  label = "lm_lin: Y~Z*(x-mean(x))"
)
```

lm_lin es el principio del plug-in aplicado al modelo lineal

La misma movida que el plug-in de Freedman para el logit de arriba: ajustamos el modelo, predecimos el resultado de cada unidad bajo $Z = 1$ y bajo $Z = 0$, promediamos y tomamos la diferencia. Para un modelo lineal con interacciones, el plug-in es `lm_lin` — dos nombres, un solo estimador.

```
set.seed(20260731)
dat3sim <- draw_data(base_design_cov)
lin_fit <- lm_lin(Y ~ Z, covariates = ~x, data = dat3sim)
ifit <- lm(Y ~ Z * x, data = dat3sim)
p1 <- predict(ifit, newdata = transform(dat3sim, Z = 1))
p0 <- predict(ifit, newdata = transform(dat3sim, Z = 0))
c(lm_lin = coef(lin_fit)[["Z"]], plugin = mean(p1) - mean(p0))
```

```
lm_lin plugin
1.567 1.567
```

(Sin la interacción, el plug-in de `lm(Y ~ Z + x)` devuelve simplemente el coeficiente de Z , así que el estimador ingenuo no gana nada con esta movida.)

El sesgo restante se puede estimar con los datos observados — y luego restar

Chang et al. (2024) escriben el sesgo exacto del estimador de Lin — covarianzas entre el *apalancamiento* (leverage) de cada unidad y su resultado — y cada término se puede estimar sin sesgo, así que restar esa estimación produce un estimador exactamente insesgado para cualquier N . Su Teorema 4.2 para una covariable:


```
cma_bias_hat <- function(Y, Z, x) {  
  n <- length(Y)  
  xs <- (x - mean(x)) / sqrt(mean((x - mean(x))^2)) # estandarizar x  
  h <- xs^2 # el apalancamiento de cada unidad  
  zt <- Z == 1  
  zc <- Z == 0  
  nT <- sum(zt)  
  nC <- sum(zc)  
  xbT <- mean(xs[zt])  
  xbC <- mean(xs[zc])  
  LT <- mean(xs[zt]^2) - xbT^2 # varianzas de x por grupo ...  
  LC <- mean(xs[zc]^2) - xbC^2  
  NT <- mean(Y[zt] * xs[zt]) - mean(Y[zt]) * xbT # ... covarianzas de x, Y  
  NC <- mean(Y[zc] * xs[zc]) - mean(Y[zc]) * xbC  
  covhT <- mean(h[zt] * Y[zt]) - mean(h[zt]) * mean(Y[zt]) # apalancamiento, Y  
  covhC <- mean(h[zc] * Y[zc]) - mean(h[zc]) * mean(Y[zc])  
  nT / ((n - 2) * nC) * covhC + xbC * (1 / LC - 1) * NC -  
  nC / ((n - 2) * nT) * covhT - xbT * (1 / LT - 1) * NT
```


El cuarto estimador: `lm_lin` menos su sesgo estimado

```
cma_est_fun <- function(data) {  
  lin_fit <- lm_lin(Y ~ Z, covariates = ~x, data = data)  
  res <- tidy(lin_fit) %>% filter(term == "Z")  
  res$estimate <- res$estimate - cma_bias_hat(data$Y, data$Z, data$x)  
  ## Conservamos el error estándar del estimador sin corregir: la  
  ## corrección no cambia la distribución de muestras grandes (Chang et  
  ## al. 2024). Observen qué le hace esto a la cobertura con  $N = 20$   
  res$conf.low <- res$estimate - qt(.975, df = res$df) * res$std.error  
  res$conf.high <- res$estimate + qt(.975, df = res$df) * res$std.error  
  return(res)  
}  
  
est_c4 <- declare_estimator(  
  handler = label_estimator(cma_est_fun), inquiry = estimandATEc,  
  label = "lm_lin - estimated bias"  
)  
  
design_cov <- base_design_cov + estimandATEc +  
  est_c1 + est_c2 + est_c3 + est_c4
```

Luego, como antes, reasignamos el tratamiento 10,000 veces y aplicamos los cuatro estimadores a cada experimento simulado.

¿Cuál estimador deberíamos usar?



Cada punto gris es la estimación de un experimento posible (100 de las 10,000); el punto negro marca el promedio.


¿Cuál estimador está más cerca del valor real?

Estimador	Sesgo	Desviación estándar	RMSE	Cobertura
Diff means: ignores x	0.01	1.93	1.93	0.90
lm_lin - estimated bias	0.02	1.31	1.31	0.63
lm_lin: $Y \sim Z^*(x - \text{mean}(x))$	-0.24	0.73	0.77	0.88
$Y \sim Z + x$: 'controls for' x	-0.73	0.92	1.18	0.81

- $Y \sim Z + x$ subestima el ATE de 2.51 por 0.73 — cerca del 29 % — y sus intervalos cubren solo el 81 % de las veces.
- `lm_lin` tiene el RMSE más pequeño; su sesgo es cerca de un tercio del sesgo ingenuo, pero no es cero.
- La corrección exacta elimina el sesgo — y lo paga con varianza. Su error estándar prestado no sabe nada de ese ruido extra, así que sus intervalos cubren solo el 63 %. La insesgadez es una propiedad entre varias, no todo el juego.
- Hasta la diferencia de medias insesgada cubre el 90 %, no el 95 %: $N = 20$ con un resultado asimétrico exige demasiado a todos los intervalos basados en la aproximación Normal.

El sesgo del ajuste se desvanece cuando el experimento crece

Copias de las mismas 20 unidades, así que solo cambia N : duplicar el experimento reduce el sesgo ingenuo aproximadamente a la mitad. A diferencia del coeficiente logit ajustado de arriba, este es un problema de muestras pequeñas, no de estimando equivocado.



Consejos sobre el ajuste de covarianza

- En experimentos medianos y grandes: ajusten con unas pocas covariables **preespecificadas** que predigan el resultado, usando `lm_lin()` — o, de manera idéntica, el plug-in con un modelo lineal interactuado (Lin 2013). Ganan precisión; el sesgo restante es de orden $1/N$.
- En experimentos pequeños (decenas de unidades): el sesgo puede ser una fracción visible del efecto y puede distorsionar la cobertura. Reporten la diferencia de medias sin ajustar junto a cualquier estimación ajustada, y prefieran usar las covariables en el **diseño** (bloques) y no en el análisis.
- Existe una corrección exactamente insesgada (Chang et al. 2024). Cambia sesgo por varianza: con $N = 20$ el RMSE siguió favoreciendo a `lm_lin`. Elijan estimadores por sus propiedades — sesgo, precisión, cobertura — simulando su propio diseño, como en toda esta sesión.
- Elijan las covariables antes de ver los resultados. Ajustar después de mirar invita a la pesca de resultados (más sobre esto en la sesión de transparencia).

Sección 8

Conclusión

Reflexiones finales sobre los conceptos básicos de la estimación

- Los estimandos causales contrafactuales son funciones de resultados potenciales no observados
- Los estimadores son recetas o fórmulas computacionales que utilizan datos observados para aprender sobre un estimando.
- Los buenos estimadores producen estimaciones cercanas al valor real del estimando.
- (Conectando los conceptos de estimación y pruebas) Los errores estándar de los estimadores nos permiten calcular intervalos de confianza y valores p . Ciertos estimadores tienen errores estándar más grandes o más pequeños (o más o menos correctos).
- Pueden evaluar la utilidad de un estimador elegido para un estimando dado utilizando una simulación.

Sección 9

Efectos causales que varían por grupos o por covariables

Efectos que varían de acuerdo al grupo I

Si nuestra teoría sugiere que los efectos varían de acuerdo a los grupos, ¿qué podemos hacer para evaluar la evidencia a favor o en contra de dichas teorías?

- Podemos **diseñar** una evaluación de esta teoría creando un estudio aleatorizado en bloque; los bloques estarían definidos de acuerdo a los grupos relevantes según la teoría.
- Podemos **planificar** para hacer dicha evaluación mediante (1) un **pre-registro del análisis de subgrupo** a realizar antes de la realización del experimento y la recolección de datos (si bloqueamos o no ese grupo en la fase de diseño) y (2) asegurarse de medir la pertenencia al grupo durante la recolección de datos inicial previa al tratamiento

Efectos que varían de acuerdo al grupo II

- Si no lo hemos planeado con anticipación, los análisis específicos de subgrupos pueden ser útiles como exploraciones, pero no deben entenderse como confirmatorias: también probar demasiadas hipótesis puede inflar la tasa de falsos positivos.
- **No debemos utilizar grupos creados por el tratamiento.** (Esto sería “análisis de mediación” o “condicionamiento de variables posteriores al tratamiento” y a esto le dedicamos un módulo propio).


Sección 10

Efectos causales cuando no controlamos la dosis

Definiendo efectos causales I

Supongamos que vamos a realizar un experimento de comunicación puerta a puerta en el que algunos hogares se asignan al azar para recibir una visita. Tengan en cuenta que ahora usamos Z y d en lugar de T .

- Z_i es la asignación aleatoria a una visita ($Z_i = 1$) o no ($Z_i = 0$).
- $d_{i,Z_i=1} = 1$ quiere decir que la persona i abre la puerta para tener una conversación cuando se le asigna una visita.
- $d_{i,Z_i=1} = 0$ quiere decir que la persona i no abre la puerta para conversar cuando se le asigna una visita.
- Abrir la puerta es un resultado del tratamiento.



Definiendo efectos causales II

- $y_{i,Z_i=1,d_{i,Z_i=1}=1}$ es el resultado potencial para las personas a las que se les asignó una visita y que sí abrieron la puerta. (“los que cumplen” o “los que siempre toman”)
- $y_{i,0,d_{i,0}=1}$ es el resultado potencial para las personas a las que no se les asignó una visita y abren la puerta. (“los que desafían” o “los que siempre lo toman”)
- $y_{i,0,d_{i,0}=0}$ es el resultado potencial para las personas a las que no se les asignó una visita y que no abren la puerta. (“los que cumplen” o “los que nunca lo toman”)

Definición de efectos causales III

También podríamos utilizar $y_{i,Z_i=0,d_{i,Z_i=1}=1}$ para definir las personas a las que no se les asignó una visita pero que habrían abierto la puerta si se les hubiera asignado una visita, etc.

En este caso, podemos simplificar nuestros resultados potenciales:

- $y_{i,0,d_{i,1}=1} = y_{i,0,d_{i,1}=0} = y_{i,0,d_{i,0}=0}$ porque su resultado es el mismo independientemente de que abra o no la puerta.

Definición de efectos causales IV

Podemos simplificar las formas en que las personas reciben una dosis del tratamiento como tal (donde d minúscula refleja la idea de que si alguien abre la puerta cuando se visita o no es un atributo fijo, como un resultado potencial).

- Y : variable de resultado ($y_{i,Z}$ o $y_{i,Z_i=1}$ para el resultado potencial de tratamiento por persona i , fijo)
- X : covariable/variable de referencia
- Z : asignación del tratamiento ($Z_i = 1$ si se asigna a una visita, $Z_i = 0$ si no se asigna a una visita)
- D : tratamiento recibido ($D_i = 1$ si la persona i abre la puerta, $D_i = 0$ si decide no abrir la puerta)
(usando D aquí porque $D_i = d_{i,1}Z_i + d_{i,0}(1 - Z_i)$)

Definición de efectos causales V

Tenemos dos efectos causales relacionados a Z : $Z \rightarrow Y$ (δ , ITT, ITT_Y) y $Z \rightarrow D$ (GG llama a esto ITT_D).

Y diferentes tipos de personas pueden reaccionar de manera diferente cuando se trata de variar la dosis junto con el instrumento.

		$Z = 1$	
		$D = 0$	$D = 1$
$Z = 0$	$D = 0$	los que nunca lo toman	los que cumplen
	$D = 1$	los que desafían	los que siempre lo toman

Definición de efectos causales VI

$$ITT = ITT_Y = \delta = \bar{y}_{Z=1} - \bar{y}_{Z=0}.$$

Pero, en este diseño, $\bar{y}_{Z=1} = \bar{y}_1$ está dividido en partes: el valor de la variable de resultado para aquellos que abrieron la puerta (los que cumplen, los que siempre lo toman y los que desafían). Utilizamos p_C para definir la proporción de cumplidores en el estudio.

$$\bar{y}_1 = (\bar{y}_1|C)p_C + (\bar{y}_1|A)p_A + (\bar{y}_1|N)p_N + (\bar{y}_1|D)p_D. \quad (3)$$

Y $\bar{y}_0$ también se divide en partes

$$\bar{y}_0 = (\bar{y}_0|C)p_C + (\bar{y}_0|A)p_A + (\bar{y}_0|N)p_N + (\bar{y}_0|D)p_D. \quad (4)$$

Definiendo efectos causales VII

Entonces, el ITT es en sí mismo una combinación de los efectos de Z en Y dentro de estos diferentes grupos (pueden imaginar que los sustituyen y luego los reorganizan para que podamos tener un grupo de ITTs, uno para cada tipo de sujeto). Pero igual podemos estimar el ITT porque tenemos estimadores insesgados de $\bar{y}_1$ y $\bar{y}_0$ dentro de cada tipo.

Aprendiendo sobre el ITT I

Primero podemos aprender sobre el efecto de la política en sí. Para calcular el ITT, no es necesario que consideremos todos los tipos de sujetos que vimos previamente. No tenemos sujetos que desafían ($p_D = 0$) y sabemos que el ITT tanto para los que siempre toman como para los que nunca toman es 0.

$$\bar{y}_1 = (\bar{y}_1|C)p_C + (\bar{y}_1|A)p_A + (\bar{y}_1|N)p_N \quad (5)$$

$$\bar{y}_0 = (\bar{y}_0|C)p_C + (\bar{y}_0|A)p_A + (\bar{y}_0|N)p_N \quad (6)$$

Aprendiendo sobre ITT II

Primero podemos aprender sobre el efecto de la política en sí. Para calcular el ITT, no es necesario que consideremos todos los tipos de sujetos que vimos previamente. En este caso, no tenemos sujetos que desafían ($p_D = 0$) y sabemos que el ITT tanto para los que siempre toman como para los que nunca toman es 0.

$$ITT = \bar{y}_1 - \bar{y}_0 \quad (7)$$

$$= ((\bar{y}_1|C)p_C + (\bar{y}_1|A)p_A + (\bar{y}_1|N)p_N) - \quad (8)$$

$$((\bar{y}_0|C)p_C + (\bar{y}_0|A)p_A + (\bar{y}_0|N)p_N) \quad (9)$$

Recopilar cada tipo de sujeto para tener un ITT para cada uno.

$$= ((\bar{y}_1|C)p_C - (\bar{y}_0|C)p_C) + ((\bar{y}_1|A)p_A - (\bar{y}_1|A)p_A) + \quad (10)$$

$$((\bar{y}_1|N)p_N - (\bar{y}_0|N)p_N) \quad (11)$$

$$= ((\bar{y}_1|C) - (\bar{y}_0|C))p_C + \quad (12)$$

$$((\bar{y}_1|A) - (\bar{y}_0|A))p_A + ((\bar{y}_1|N) - (\bar{y}_0|N))p_N \quad (13)$$

Aprendiendo sobre ITT III

$$ITT = \bar{y}_1 - \bar{y}_0 \quad (14)$$

$$= ((\bar{y}_1|C)p_C + (\bar{y}_1|A)p_A + (\bar{y}_1|N)p_N) - \quad (15)$$

$$((\bar{y}_0|C)p_C + (\bar{y}_0|A)p_A + (\bar{y}_0|N)p_N) \quad (16)$$

$$= ((\bar{y}_1|C)p_C - (\bar{y}_0|C)p_C) + ((\bar{y}_1|A)p_A - (\bar{y}_0|A)p_A) + \quad (17)$$

$$((\bar{y}_1|N)p_N - (\bar{y}_0|N)p_N) \quad (18)$$

$$= ((\bar{y}_1|C) - (\bar{y}_0|C))p_C + ((\bar{y}_1|A) - (\bar{y}_0|A))p_A + \quad (19)$$

$$((\bar{y}_1|N) - (\bar{y}_0|N))p_N \quad (20)$$

Aprendiendo sobre ITT IV

Y si el efecto de la dosis sólo puede darse para aquellos que abren la puerta y sólo aquellos que fueron asignados al tratamiento pueden abrir la puerta, entonces:


$$((\bar{y}_1|A) - (\bar{y}_0|A))p_A = 0 \text{ y } ((\bar{y}_1|N) - (\bar{y}_0|N))p_N = 0 \quad (21)$$

$$ITT = ((\bar{y}_1|C) - (\bar{y}_0|C))p_C = (CACE)p_C. \quad (22)$$

El efecto causal promedio de los que cumplen I

También puede resultarnos interesante aprender sobre el efecto causal de abrir la puerta y el de conversar, el efecto teóricamente interesante.

Pero esta comparación está asociada con x : una simple comparación $\bar{Y}|D = 1 - \bar{Y}|D = 0$ nos deja ver las diferencias en la variable de resultado ocasionadas por x además de la diferencia causada por D . (Los números que se muestran a continuación están basados en una simulación)



El efecto causal promedio de los que cumplen II

```
with(dat, cor(Y, x)) ## puede ser cualquier número  
with(dat, cor(d, x)) # puede ser cualquier número  
with(dat, cor(Z, x)) ## debe estar cerca de cero
```

Sin embargo, acabamos de ver que en este diseño y con estos supuestos (incluido el supuesto SUTVA)
 $ITT = ((\bar{y}_1|C) - (\bar{y}_0|C))p_C = (CACE)p_C$, por lo tanto podemos definir $CACE = ITT/p_C$.

Cómo calcular el ITT y CACE/LATE I

Algunos ejemplos de datos (en los que conocemos todos los resultados potenciales):

X	u	type	Z	pZ	DZ1	YD0Z0	YD1Z0	YD0Z1	YD1Z1	D	Y
2	1.30	Complier	1	0	1	1.30	1.73	1.30	1.73	1	1.73
3	1.12	Complier	0	0	1	1.12	1.55	1.12	1.55	0	1.12

Cómo calcular el ITT y CACE/LATE II

El ITT y CACE (las partes)

```
itt_y <- difference_in_means(Y ~ Z, data = dat0)
itt_y
```

Design: Standard

	Estimate	Std. Error	t value	Pr(> t)	CI Lower	CI Upper	DF
Z	0.06457	0.1712	0.3772	0.7068	-0.2751	0.4043	97.84

```
itt_d <- difference_in_means(D ~ Z, data = dat0)
itt_d
```

Design: Standard

	Estimate	Std. Error	t value	Pr(> t)	CI Lower	CI Upper	DF
Z	0.68	0.07307	9.307	8.454e-15	0.5348	0.8252	89.31

Cómo calcular el ITT y CACE/LATE III

Reuniendo todo:¹

```
cace_est <- iv_robust(Y ~ D | Z, data = dat0)
cace_est
```

	Estimate	Std. Error	t value	Pr(> t)	CI Lower	CI Upper	DF
(Intercept)	0.39841	0.1372	2.9046	0.004545	0.1262	0.6706	98
D	0.09495	0.2514	0.3778	0.706412	-0.4038	0.5938	98

igual que:

```
coef(itt_y)[["Z"]] / coef(itt_d)[["Z"]]
```

```
[1] 0.09495
```

¹funciona bien cuando $Z \rightarrow D$ no es débil. Vean Imbens y Rosenbaum (2005) para una historia con moraleja al respecto

Resumen de diseños orientados al estímulo/cumplidor/dosis:

- Analizar conforme se aleatoriza, incluso cuando no hay control de la dosis
- El peligro del análisis por protocolo.

Referencias

Chang, Haoge, Joel A. Middleton, y P. M. Aronow. 2024. «Exact Bias Correction for Linear Adjustment of Randomized Controlled Trials». *Econometrica* 92 (5): 1503-19. <https://doi.org/10.3982/ECTA20289>.

Freedman, David A. 2008a. «On regression adjustments to experimental data». *Advances in Applied Mathematics* 40 (2): 180-93.

Freedman, David A. 2008b. «Randomization does not justify logistic regression». *Statistical Science* 23 (2): 237-49.

Imbens, Guido W., y Paul R. Rosenbaum. 2005. «Robust, accurate confidence intervals with a weak instrument: quarter of birth and education». *Journal of the Royal Statistical Society Series A* 168 (1): 109-26.

Lin, Winston. 2013. «Agnostic notes on regression adjustments to experimental data: Reexamining Freedman's critique». *The Annals of Applied Statistics* 7 (1): 295-318.